PRA-SKRIPSI

ANALISIS STABILITAS KINERJA RELATIF LIGHTGBM TERHADAP HAR-RV DALAM PERAMALAN REALIZED VARIANCE BITCOIN

FERDI ENDAHAS AHMAD
NPM 23081010165

DOSEN PEMBIMBING
Dr. Rizky Parlika, S.Kom, M.Kom
Nama Dosen Pembimbing 2, Gelar

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR
FAKULTAS ILMU KOMPUTER
PROGRAM STUDI INFORMATIKA
SURABAYA
2026

DAFTAR ISI

DAFTAR ISI ..... **ii**
DAFTAR GAMBAR ..... **iv**
DAFTAR TABEL ..... **v**
DAFTAR NOTASI ..... **vi**
BAB I PENDAHULUAN **1**
1.1. Latar Belakang 1
1.2. Rumusan Masalah 5
1.3. Tujuan Penelitian 5
1.4. Manfaat Penelitian 6
1.4.1. Manfaat Teoretis 6
1.4.2. Manfaat Praktis 6
1.5. Batasan Masalah 6
BAB II TINJAUAN PUSTAKA **8**
2.1. Penelitian Terdahulu 8
2.2. Landasan Teori 11
2.2.1. Bitcoin dan Evolusi Karakteristik Pasarnya 11
2.2.2. Efisiensi Pasar dan Keterramalan Volatilitas 11
2.2.3. Realized Variance sebagai Proksi Volatilitas 12
2.2.4. Model Heterogeneous Autoregressive (HAR-RV) 13
2.2.5. LightGBM 14
2.2.6. Fitur Berbasis Data Intraday 15
2.2.7. Fungsi Loss untuk Evaluasi Peramalan Volatilitas 16
2.2.8. Uji Perbandingan Akurasi Peramalan 17
2.2.9. Instabilitas Kinerja Peramalan dan Uji Perubahan Struktural 17
2.2.10. Evaluasi Out-of-Sample dan Strategi Pembaruan Model 18
2.2.11. Pergeseran Distribusi Data 20
2.2.12. Proksi Likuiditas 21
2.3. Kerangka Pemikiran 21
2.4. Hipotesis Penelitian 22

BAB III METODOLOGI 25
3.1. Metode Penelitian 25
3.1.1. Alur Penelitian 25
3.1.2. Tahap Uji Kelayakan 26
3.1.3. Peralatan Penelitian 27
3.2. Desain Sistem 27
3.2.1. Data 27
3.2.2. Audit dan Pra-pemrosesan Data 28
3.2.3. Target dan Fitur 29
3.2.4. Model 30
3.2.5. Aturan Teknis Peramalan 30
3.2.6. *Tuning Hyperparameter* 31
3.2.7. Skema Pembaruan Model (*Walk-Forward*) 32
3.2.8. Kontrol Kebocoran Data 32
3.3. Perhitungan Manual 33
3.3.1. *Realized Variance* dan Komponen HAR 33
3.3.2. Fitur X 34
3.3.3. Peramalan HAR-RV dan LGBM-HAR 35
3.3.4. Evaluasi Satu Hari 36
3.4. Evaluasi dan Pengujian Hipotesis 36
3.4.1. Fungsi *Loss* dan Selisih *Loss* 36
3.4.2. Uji Konfirmatori 36
3.4.3. Variabel Karakteristik Pasar (RQ2) 37
3.4.4. Analisis Eksploratori 38
3.4.5. Uji Sensitivitas 39
3.5. Jadwal Penelitian 39
DAFTAR PUSTAKA 40
LAMPIRAN 1 CONTOH LAMPIRAN 45

DAFTAR GAMBAR

Gambar 2.1 Ilustrasi Komponen Harian, Mingguan, dan Bulanan pada Model HAR-RV 13
Gambar 2.2 Pertumbuhan Pohon *Level-wise* dan *Leaf-wise* 14
Gambar 2.3 Skema Strategi Pembaruan Model Static, Expanding, dan Rolling 20
Gambar 2.4 Kerangka Pemikiran Penelitian 23

Gambar 3.1 Alur Penelitian 26
Gambar 3.2 Harga Penutupan dan *Realized Variance* Harian BTC/USDT Spot, 17 Agustus 2017–30 September 2026 28
Gambar 3.3 Struktur Pohon ke-1 dan ke-2 LGBM-HAR pada Contoh Perhitungan 35

DAFTAR TABEL

Tabel 2.1 Matriks Posisi Penelitian terhadap Penelitian Terdahulu 10

Tabel 2.2 Strategi Pembaruan Model dan Padanannya dalam Literatur 19

Tabel 2.3 Perbandingan Istilah Pergeseran Data menurut Gama dkk. dan Moreno-Torres dkk. 20

Tabel 2.4 Desain Perbandingan Model 2×2 22

Tabel 2.5 Ringkasan Rumusan Masalah, Hipotesis, dan Uji Konfirmatori ... 24

Tabel 3.1 Ringkasan Data Penelitian 27

Tabel 3.2 Fitur dan Model Pemakainya 29

Tabel 3.3 Ruang Pencarian dan *Hyperparameter* Terkunci 32

Tabel 3.4 Skema Pembaruan dan Awal Periode *Out-of-Sample* 32

Tabel 3.5 Lima Bar Pertama Hari t^* dan Komponennya. 33

Tabel 3.6 Komponen HAR pada Hari t^* 34

Tabel 3.7 Fitur X pada Hari t^* 34

Tabel 3.8 Evaluasi Ramalan 31 Agustus 2018 36

Tabel 3.9 Variabel Karakteristik Pasar Bulanan 37

Tabel 3.10 Variasi Uji Sensitivitas 39

Tabel 3.11 Jadwal Penelitian 39

DAFTAR NOTASI

$r_{t,i}$	:	*Return* logaritmik intraday pada bar ke-i hari t
$C_{t,i}$	:	Harga penutupan bar 5 menit ke-i pada hari t; untuk $i = 1$, $C_{t,0}$ adalah harga penutupan bar terakhir hari $t - 1$
i	:	Nomor urut bar 5 menit dalam satu hari, bernilai 1 sampai 288
RV_t	:	*Realized variance* harian pada hari t, yaitu komponen harian
$RV_t^{(w)}$	:	Rata-rata RV tujuh hari terakhir hingga hari t, yaitu komponen mingguan
$RV_t^{(m)}$	:	Rata-rata RV tiga puluh hari terakhir hingga hari t, yaitu komponen bulanan
j	:	Indeks pergeseran hari ke belakang dari hari t
RV_{t+1}	:	RV hari berikutnya, yaitu target peramalan
β_0	:	Konstanta regresi HAR-RV
β_d	:	Koefisien komponen harian
β_w	:	Koefisien komponen mingguan
β_m	:	Koefisien komponen bulanan
ε_{t+1}	:	Galat regresi HAR-RV yang diasumsikan berrata-rata nol
$F_b(\mathbf{x})$	:	Model GBDT gabungan setelah b iterasi
$h_b(\mathbf{x})$	:	Pohon ke-b, dilatih pada gradien fungsi *loss*
η	:	Laju pembelajaran
RS_t^-	:	*Realized semivariance* negatif pada hari t
$\mathbf{1}(\cdot)$	:	Fungsi indikator, bernilai 1 bila syarat di dalamnya terpenuhi dan 0 bila tidak
$\sigma_{P,t}^2$	:	Estimator varians *range* Parkinson pada hari t
P_t^H	:	Harga tertinggi pada hari t
P_t^L	:	Harga terendah pada hari t
Amihud_t	:	Ukuran *illiquidity* pada hari t
$QV_{t,i}$	:	Volume dalam dolar (USDT) pada bar ke-i
N_t	:	Jumlah bar bervolume positif pada hari t
10^6	:	Faktor penskalaan ukuran Amihud agar besarannya mudah dibaca
F_t	:	Ramalan RV untuk hari t
L_t^{QLIKE}	:	Nilai *loss* QLIKE pada hari t
L_t^{MSE}	:	Nilai *loss* MSE pada hari t
ΔL_t	:	Selisih *loss* harian antara model *machine learning* dan HAR-RV

$L_t(\mathrm{ML})$	:	*Loss* model *machine learning* pada hari t
$L_t(\mathrm{HAR})$	:	*Loss* model HAR-RV pada hari t
DM	:	Statistik uji Diebold–Mariano
$\overline{\Delta L}$	:	Rata-rata selisih *loss* selama periode uji
$\widehat{V}_{\mathrm{HAC}}$	:	Estimator varians jangka panjang yang konsisten terhadap heteroskedastisitas dan autokorelasi
n	:	Jumlah observasi pada periode uji
UDmax	:	Statistik uji perubahan struktural maksimum
$\sup F_T(m)$	:	Statistik F terbesar atas semua kemungkinan penempatan m titik patah
m	:	Jumlah titik patah pada uji Bai–Perron
M	:	Jumlah maksimum titik patah yang diuji
ε	:	Proporsi *trimming*, yaitu panjang minimum tiap segmen pada uji Bai–Perron
μ	:	Fraksi ukuran jendela bergulir pada *Fluctuation test*, dengan $n_F = \mu n$
n_F	:	Ukuran jendela bergulir pada *Fluctuation test*
D^{KS}	:	Statistik Kolmogorov–Smirnov dua sampel
$\hat{F}_{\mathrm{latih}}(x)$	:	Fungsi distribusi kumulatif empiris data latih
$\hat{F}_{\mathrm{uji}}(x)$	:	Fungsi distribusi kumulatif empiris bulan uji
$\sup_x$	:	Nilai terbesar atas seluruh x
D_t	:	Selisih ΔL_t antara strategi pembaruan S2-365 dan S1
W	:	Panjang jendela data latih *rolling*, dalam hari
C_t	:	Harga penutupan bar terakhir hari t
t^*	:	Hari contoh pada perhitungan manual (30 Agustus 2018)
$\hat{y}_{t+1}$	:	Ramalan $\ln RV_{t+1}$ sebelum dikembalikan ke skala level
$\hat{\sigma}^2$	:	Varians residual untuk koreksi bias transformasi logaritma
$\underline{F}$	:	Batas bawah ramalan, persentil ke-1 target RV pada *window* latih
F_{t+1}	:	Ramalan RV hari $t+1$ setelah koreksi bias dan batas bawah
$\bar{p}_t$	:	Rata-rata logaritma harga tertinggi dan terendah hari t pada estimator Abdi–Ranaldo
c_t	:	Logaritma harga penutupan hari t
s_t	:	*Spread* Abdi–Ranaldo harian
τ	:	Indeks bulan uji pada regresi karakteristik pasar
$\overline{\Delta L}_\tau$	:	Rata-rata ΔL_t pada bulan τ
$z_{k,\tau}$	:	Variabel karakteristik pasar ke-k pada bulan τ
k	:	Indeks variabel karakteristik pasar, bernilai 1 sampai 4
γ_k	:	Koefisien variabel karakteristik pasar ke-k

α	:	Konstanta regresi karakteristik pasar dan regresi era
δ	:	Koefisien variabel *dummy* era
Era_τ	:	Variabel *dummy* era *institutional* pada bulan τ
Era_t	:	Variabel *dummy* era *institutional* pada hari t
u_τ	:	Galat regresi karakteristik pasar bulan τ
e_t	:	Galat regresi era pada hari t
ℓ	:	Jumlah titik patah pada uji perubahan berurutan sup $F(\ell+1 \mid \ell)$
R	:	Jumlah replikasi simulasi Monte Carlo
R^+	:	Jumlah statistik simulasi yang tidak lebih kecil daripada statistik amatan

BAB I
PENDAHULUAN

1.1. Latar Belakang

Sejak diperkenalkan sebagai sistem uang elektronik tanpa lembaga perantara [1], Bitcoin telah melewati tiga era pasar. Era *niche* didominasi pengguna awal, era *transition* diikuti investor perorangan secara luas, dan era *institutional* melibatkan lembaga keuangan, termasuk melalui ETF spot sejak 2024. Dari era ke era, volatilitas turun tajam, volume transaksi naik, biaya transaksi turun, dan likuiditas makin tahan terhadap guncangan [2]. Namun, perubahan tersebut tidak berjalan mulus. Tingkat efisiensi pasar Bitcoin berganti-ganti antara periode efisien dan tidak efisien [3]. Kondisi ini memunculkan pertanyaan penting bagi peramalan: apakah model yang paling akurat pada satu periode masih paling akurat ketika kondisi pasar sudah berubah?

Penelitian tentang efisiensi pasar Bitcoin umumnya menguji apakah *return* dapat ditebak dari harga masa lalu [3], [4]. Pertanyaan ini berbeda dengan peramalan volatilitas. Sulitnya menebak arah return tidak berarti besarnya perubahan harga, atau volatilitas, juga sulit diramalkan. Ramalan volatilitas tetap dibutuhkan dalam penentuan harga opsi, alokasi portofolio, lindung nilai, dan pengelolaan risiko [5], [6].

Masalahnya, volatilitas tidak dapat diamati secara langsung sehingga harus diukur dari data harga. Salah satu ukuran yang umum dipakai yaitu *realized variance* (RV). RV merupakan jumlah kuadrat return intrahari dalam satu hari, sedangkan return merupakan perubahan logaritma harga pada selang waktu pendek, misalnya lima menit. RV berada pada skala varians, sedangkan volatilitas umumnya dinyatakan sebagai akar kuadratnya. Penelitian ini bekerja pada skala varians, dan kata volatilitas dipakai untuk menyebut konsep umumnya. Ukuran volatilitas dari kuadrat return harian sangat berisik, sehingga model peramalan dapat terlihat buruk padahal ramalannya cukup akurat. Ketika diukur dengan RV dari return lima menit, model yang sama terlihat jauh lebih akurat [5]. Pada 31 aset dari lima kelas aset, RV dari return lima menit juga sulit dikalahkan secara signifikan oleh ukuran lain yang lebih rumit [7].

Salah satu model untuk meramalkan RV merupakan *Heterogeneous Autoregressive model of Realized Volatility* (HAR-RV). Model ini memanfaatkan sifat volatilitas yang cenderung bertahan lama, yaitu besarnya perubahan harga hari ini masih berkaitan dengan besarnya perubahan harga hingga beberapa bulan sebelumnya. HAR-RV meramalkan RV hari berikutnya dari rata-rata RV harian, mingguan, dan bulanan. Walaupun hanya berupa regresi linear sederhana, HAR-RV lebih akurat daripada model autoregresif biasa dan hasilnya sebanding dengan model memori panjang yang lebih rumit [8]. Pada aset kripto yang diperdagangkan setiap hari tanpa libur, rata-rata mingguan dan bulanan pada HAR-RV disesuaikan menjadi 7 dan 30 hari [9].

Selain model ekonometrika, model *machine learning* (ML) juga mulai dipakai untuk meramalkan volatilitas aset kripto. Pada empat aset kripto, *random forest* dan LSTM menghasilkan ramalan volatilitas yang signifikan lebih akurat daripada model GARCH [10]. Di antara model ML, penelitian ini memilih LightGBM. LightGBM merupakan implementasi *gradient boosting decision tree* (GBDT), yaitu model yang menggabungkan banyak pohon keputusan secara bertahap. LightGBM dipilih karena tiga alasan. Pertama, LightGBM dirancang untuk mempercepat pelatihan GBDT dengan akurasi yang hampir sama [11]. Kecepatan ini penting karena model dalam penelitian ini dilatih ulang berkali-kali. Kedua, pada data tabular berukuran menengah, model berbasis pohon masih lebih unggul daripada *deep learning* [12]. Ketiga, LightGBM banyak dipakai dalam peramalan. Pada kompetisi peramalan M5, semua metode teratas merupakan metode ML, dan LightGBM dipakai oleh tim-tim teratas. Namun, keunggulan tersebut didukung oleh banyaknya deret data yang saling berkaitan dan data tambahan [13], kondisi yang berbeda dengan peramalan satu deret volatilitas. Pemilihan LightGBM tidak dimaksudkan untuk menyatakan bahwa LightGBM lebih unggul daripada model ML lain. LightGBM dipakai sebagai wakil model berbasis pohon yang efisien untuk dilatih ulang secara berkala.

Sejumlah penelitian sudah membandingkan model ML dengan HAR-RV, dan hasilnya belum seragam. Pada saham, model berbasis pohon keputusan tidak lebih baik daripada HAR-RV jika hanya diberi data yang sama dengan HAR-RV. Model tersebut baru lebih unggul setelah diberi data tambahan [14]. Pada Bitcoin,

LSTM dengan masukan yang setara dengan HAR-RV hanya sedikit lebih akurat, dan perbedaannya hanya signifikan untuk ramalan 60 hari ke depan [15]. Pada empat aset kripto, model sederhana seperti HAR-RV tidak signifikan lebih buruk daripada LSTM atau random forest. Perbedaan kinerja pada hari yang paling tenang dan paling bergejolak hanya dijelaskan, tanpa diuji secara statistik [16].

Penelitian yang khusus menguji LightGBM juga memberi hasil yang berbeda-beda. Pada RV harian Bitcoin, LightGBM menghasilkan kesalahan rata-rata yang lebih kecil daripada HAR-RV, tetapi perbedaannya umumnya tidak signifikan menurut uji Diebold–Mariano [17]. Sebaliknya, pada RV enam jam Bitcoin, HAR-RV justru signifikan lebih akurat daripada LightGBM dan model ML lain jika diukur dengan QLIKE, padahal pada aset kripto lain model ML umumnya lebih baik [18]. Pada RV saham, model berbasis pohon seperti XGBoost dan *gradient boosting* bahkan termasuk yang paling buruk di antara model ML [19], [20]. Kedua penelitian terakhir juga melaporkan hasil per tahun dan per kuartal. Pada penelitian per kuartal, model terbaik berganti dari kuartal ke kuartal. Namun, perubahan tersebut hanya dijelaskan, tanpa diuji secara statistik.

Sebagian besar penelitian di atas menilai model pada satu periode pengujian dan melaporkan hasil rata-ratanya. Cara ini memiliki kelemahan. Satu periode pengujian mungkin hanya mencerminkan satu kondisi tertentu, dan metode yang unggul pada satu periode belum tentu unggul pada periode lain [21]. Dalam bidang ML, perubahan hubungan antara data masukan dan target dari waktu ke waktu dikenal sebagai *concept drift*. Merata-ratakan akurasi sepanjang waktu dapat menutupi naik-turunnya kinerja model selama periode tersebut [22]. Sebenarnya sudah ada uji statistik untuk memeriksa apakah keunggulan satu ramalan atas ramalan lain berubah dari waktu ke waktu [23], [24]. Salah satunya, yaitu *Fluctuation test*, pernah dipakai pada Bitcoin dan Ethereum. Namun, penelitian tersebut meramalkan ukuran risiko kerugian dengan model ekonometrika, bukan membandingkan ML dengan HAR-RV dalam meramalkan RV [25]. Sejauh penelusuran penulis, belum diketahui apakah kinerja relatif LightGBM terhadap HAR-RV pada Bitcoin tetap sama sepanjang waktu, atau berubah mengikuti kondisi pasar.

Masalah berikutnya menyangkut cara memperbarui model, yaitu berapa banyak data lama yang perlu dipakai saat model dilatih ulang. Ada tiga cara yang umum. Model bisa tidak dilatih ulang sama sekali (*static*). Model juga bisa dilatih ulang hanya dengan data terbaru, misalnya satu tahun terakhir (*rolling window*). Cara lainnya yaitu melatih ulang model dengan seluruh data yang tersedia (*expanding window*). Secara teori, rolling window lebih menguntungkan bila pola data berubah besar dan sering, sedangkan expanding window lebih menguntungkan bila perubahannya kecil atau tidak ada [26]. Pada peramalan volatilitas indeks saham S&P 500 dengan HAR-RV, *window* yang lebih akurat berganti-ganti antara rolling dan expanding [27]. Pada aset kripto, rolling umumnya lebih akurat daripada expanding, tetapi perbandingan rincinya hanya untuk model GARCH, tanpa HAR-RV, dan tanpa uji statistik [28]. Penelitian ML lain pada Bitcoin hanya memakai rolling window dan mengubah panjangnya sebagai uji tambahan, tanpa membandingkannya dengan expanding window [29].

Cara memperbarui model juga memengaruhi hasil perbandingan ML dan HAR-RV. Pada 1.445 saham Amerika Serikat, model ML tidak lebih baik daripada HAR-RV jika hanya diberi data volatilitas dan HAR-RV dilatih ulang setiap hari dengan rolling window yang sesuai. Namun, pada penelitian tersebut model ML tidak dilatih ulang, sedangkan HAR-RV dilatih ulang setiap hari [6]. Artinya, perbandingan ML dan HAR-RV baru adil jika keduanya diperbarui dengan cara yang sama. Sejauh penelusuran penulis, juga belum diketahui apakah pengaruh cara memperbarui model berbeda pada era pasar yang berbeda.

Penelitian ini juga memperhatikan cara mengukur kesalahan ramalan. Saat volatilitas tinggi, selisih antara ramalan dan nilai aktual cenderung membesar karena nilai yang diramal memang besar. Jadi, kesalahan yang besar belum tentu berarti modelnya memburuk. Karena itu, penelitian ini membandingkan selisih kesalahan antara model ML dan HAR-RV pada hari yang sama. Ukuran kesalahan utamanya yaitu QLIKE. QLIKE menilai kesalahan dari perbandingan (rasio) antara nilai aktual dan ramalan, bukan dari selisihnya. Karena berbasis rasio, nilai QLIKE tidak otomatis membesar hanya karena tingkat volatilitas naik, sehingga kesalahan pada periode tenang dan periode bergejolak lebih sebanding. QLIKE juga tetap memberi urutan model yang benar walaupun proksi yang dipakai berisik, selama proksi

tersebut tidak bias. Sebagai pelengkap, dipakai juga *mean squared error* (MSE), yang memiliki sifat ketahanan yang sama [30].

Berdasarkan uraian tersebut, penelitian ini menguji apakah kinerja relatif LightGBM terhadap HAR-RV dalam meramalkan RV harian Bitcoin stabil dari waktu ke waktu. Data yang dipakai merupakan harga BTC/USDT pasar spot di Binance, dan RV dihitung dari return lima menit. Penelitian ini membandingkan empat model, yaitu HAR, HAR-X, LGBM-HAR, dan LGBM-X. Huruf X menandakan model yang diberi data pasar tambahan. Dengan cara ini, dapat dilihat apakah perbedaan kinerja LightGBM berasal dari modelnya atau dari data tambahannya. Penelitian ini juga membandingkan cara memperbarui model static, expanding, dan rolling, dengan perlakuan yang sama untuk HAR-RV. Penelitian ini mengembangkan salah satu penelitian terdahulu [16] pada tiga hal, yaitu kestabilan kinerja dari waktu ke waktu, kaitannya dengan kondisi pasar, dan pengaruh cara memperbarui model. Penelitian ini tidak mengusulkan algoritma baru. Kontribusinya berupa cara mengevaluasi model ML pada data yang terus berubah, dengan memadukan strategi pembaruan model dari bidang ML dan uji kestabilan ramalan dari bidang peramalan deret waktu. Kurangnya keterkaitan antara ML untuk data yang terus mengalir (*data stream*) dan literatur deret waktu masih disebut sebagai masalah terbuka [31].

1.2. Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah penelitian ini adalah sebagai berikut.

1. Sejauh mana kinerja relatif LightGBM terhadap HAR-RV dalam meramalkan *realized variance* Bitcoin stabil sepanjang periode pengujian?
2. Apakah perubahan kinerja relatif tersebut berasosiasi dengan karakteristik pasar dan pergeseran distribusi fitur?
3. Apakah strategi pembaruan model dan panjang *window* data latih memengaruhi kinerja relatif LightGBM terhadap HAR-RV secara berbeda pada era pasar yang berbeda?

1.3. Tujuan Penelitian

Tujuan penelitian ini adalah sebagai berikut.

1. Menguji secara statistik apakah kinerja relatif LightGBM terhadap HAR-RV dalam meramalkan *realized variance* Bitcoin stabil sepanjang periode pengujian.
2. Menganalisis keterkaitan perubahan kinerja relatif tersebut dengan karakteristik pasar dan pergeseran distribusi fitur, termasuk apakah kontribusi data pasar tambahan berbeda antarera.
3. Menganalisis pengaruh strategi pembaruan model dan panjang *window* data latih terhadap kinerja relatif LightGBM terhadap HAR-RV pada era pasar yang berbeda, dengan perlakuan yang sama untuk HAR-RV.

1.4. Manfaat Penelitian

1.4.1. Manfaat Teoretis

Penelitian ini memberikan bukti tentang kestabilan kinerja model ML dibandingkan model sederhana dalam meramalkan volatilitas Bitcoin pada era pasar yang berbeda. Penelitian ini juga menyediakan cara evaluasi yang dapat diulang pada aset atau model lain, mulai dari pengolahan data, cara memperbarui model, hingga uji kestabilan.

1.4.2. Manfaat Praktis

Bagi pengembang sistem peramalan, hasil penelitian ini dapat membantu menentukan apakah model ML layak dipakai dibandingkan model sederhana, kapan kinerjanya cenderung berubah, dan seberapa banyak data lama yang sebaiknya dipakai saat model dilatih ulang. Manfaat ini tetap ada apa pun hasilnya, baik ML lebih unggul, setara, maupun lebih buruk.

1.5. Batasan Masalah

Batasan masalah penelitian ini adalah sebagai berikut.

1. Data yang dipakai merupakan harga BTC/USDT pasar spot dari arsip publik Binance dengan resolusi lima menit, dari Agustus 2017 hingga September 2026. Hasil penelitian tidak berlaku umum untuk pasar *perpetual* atau bursa lain.
2. Variabel yang diramalkan yaitu *realized variance* harian untuk satu hari ke depan.

3. Model yang dibandingkan yaitu HAR-RV, HAR-X, LGBM-HAR, dan LGBM-X, ditambah model naif sebagai pembanding dasar. Model *deep learning* tidak termasuk.
4. Periode pengujian mencakup era *transition* dan *institutional*. Era *niche* tidak tercakup karena data spot Binance baru tersedia sejak 2017.
5. Semua variabel pasar dihitung dari data harga dan volume. Penelitian ini melihat keterkaitan, bukan sebab-akibat.

BAB II
TINJAUAN PUSTAKA

2.1. Penelitian Terdahulu

Penelitian terdahulu yang relevan dikelompokkan ke dalam lima kelompok: perbandingan model ML dengan HAR untuk volatilitas, perbandingan model berbasis pohon dengan HAR, uji instabilitas peramalan pada aset kripto, pengaruh *window* data latih, serta perubahan karakteristik pasar Bitcoin.

Perbandingan ML dan HAR untuk volatilitas. Dudek dkk. merupakan penelitian acuan utama. Penelitian tersebut membandingkan 12 metode untuk volatilitas harian BTC, ETH, LTC, dan XMR dari bursa Kraken, dengan RV dari *return* 5 menit, *rolling window* 23 bulan, dan pelatihan ulang setiap hari pada periode uji 2019–2021 [16]. Model sederhana seperti HAR tidak signifikan lebih buruk daripada LSTM atau *random forest*, sedangkan kinerja pada 5% hari dengan RV terendah dan tertinggi hanya dibandingkan secara deskriptif tanpa uji signifikansi. Huang, Sangiorgi, dan Urquhart meramalkan RV Bitcoin dari data tik Bitstamp 2014–2021 dengan periode uji sekitar 290 hari [15]. Dengan masukan setara HAR, LSTM hanya unggul tipis, paling besar 1,56%, dan perbedaannya hanya signifikan menurut uji DM pada horizon 60 hari. Pada horizon satu hari, HAR terlihat lebih tahan terhadap lonjakan volatilitas dibanding CNN-LSTM, tetapi hal ini hanya ditunjukkan melalui grafik. Pada saham DJIA, Christensen dkk. menemukan bahwa *random forest* dengan masukan HAR saja sekitar setara dengan HAR dan *gradient boosting* lebih buruk, sedangkan keunggulan model ML baru muncul setelah prediktor tambahan dimasukkan [14]. Wang, Andreeva, dan Martin-Barragan menunjukkan bahwa *random forest* dan LSTM mengungguli GARCH untuk volatilitas empat aset kripto, dengan determinan internal pasar sebagai prediktor terpenting [10]. Feng, Qi, dan Lucey meramalkan RV BTC/USD 2017–2022 dengan Lasso, Ridge, dan Elastic Net yang *hyperparameter*-nya dituning ulang setiap hari, dan menemukan bahwa ketiganya mengungguli HAR-RV serta kepentingan indikator *blockchain* meningkat sejak Oktober 2022 [29]. Qiu dkk. menunjukkan bahwa pada RV sepuluh aset kripto di Binance, kombinasi ramalan dari beberapa model HAR dan *rough volatility* umumnya mengungguli model

tunggal [9]. Oprea dan Bâra mengkaji peran *regime*, tetapi menargetkan harga, bukan volatilitas, dan tanpa HAR sebagai pembanding [32].

Model berbasis pohon dan HAR. Dudek, Kasprzyk, dan Pełka meramalkan RV harian BTC/USD dengan LightGBM dan 69 prediktor [17]. LightGBM menghasilkan MSE lebih rendah daripada HAR, tetapi uji DM hanya signifikan pada satu perbandingan, dan menurut uji Wilcoxon LightGBM tidak lebih baik daripada *random forest*. Penelitian tersebut masih berupa *preprint*. Brauneis dan Sahiner membandingkan HAR dengan LightGBM, XGBoost, dan beberapa model *deep learning* pada RV enam jam delapan aset kripto [18]. Pada sebagian besar aset kripto, model ML lebih baik, tetapi pada Bitcoin HAR justru signifikan lebih akurat daripada semua model ML menurut QLIKE. Pada RV S&P 500, Kılıç menemukan XGBoost sebagai model ML terburuk, dengan penurunan kinerja paling parah pada krisis 2008 [19]. Pada RV saham Rusia, Pyrlik, Elizarov, dan Leonova menemukan bahwa Lasso dan HAR-RV paling baik, sedangkan *gradient boosting* paling buruk, dan model terbaik berganti dari kuartal ke kuartal [20]. Kedua penelitian terakhir melaporkan hasil per tahun atau per kuartal, tetapi perubahan kinerja relatif tersebut tidak diuji secara statistik.

Uji instabilitas peramalan pada aset kripto. Trucíos dan Taylor menerapkan *Fluctuation test* pada peramalan *Value at Risk* dan *Expected Shortfall* Bitcoin dan Ethereum dengan model ekonometrik [25]. Hasilnya, keunggulan satu model atas model lain hanya muncul sesaat pada sebagian perbandingan. Penelitian tersebut menunjukkan bahwa evaluasi sepanjang waktu relevan untuk aset kripto, tetapi tidak mencakup model ML maupun target RV.

Pengaruh *window* data latih. Feng, Zhang, dan Wang membandingkan *rolling* dan *expanding window* pada HAR-RV untuk RV S&P 500 dan menemukan bahwa *window* yang lebih baik berganti sepanjang waktu, tetapi keunggulannya cenderung bertahan dalam periode yang relatif panjang [27]. Akgun dan Gulay membandingkan sebelas model tipe GARCH dan tiga model *deep learning* untuk volatilitas Bitcoin, Ethereum, dan Binance Coin hingga akhir 2021 [28]. Perbandingan *rolling* dan *expanding* dilaporkan rinci hanya untuk model tipe GARCH, dengan hasil *rolling* umumnya lebih akurat, tanpa HAR dan tanpa uji signifikansi. Chassot dan Audrino menunjukkan pada 1.445 saham bahwa model

ML tidak mengungguli HAR ketika HAR diestimasi ulang setiap hari dengan *rolling window* yang tepat [6]. Namun, model ML pada penelitian tersebut tidak dilatih ulang, sehingga perbandingannya juga tidak sepenuhnya setara.

Perubahan pasar Bitcoin dan peran *regime*. Do membagi pasar Bitcoin 2012–2025 ke dalam tiga era dan menunjukkan bahwa respons *illiquidity* terhadap guncangan volatilitas melemah pada era *institutional* [2]. Mokni dkk. menunjukkan bahwa efisiensi pasar Bitcoin berganti-ganti, dan pengaruh likuiditas terhadap efisiensi berbeda arah antarkuantil sebelum COVID-19 serta jauh lebih besar sesudahnya [3]. Agakishiev dkk. menemukan bahwa manfaat informasi *regime* tidak signifikan pada data validasi dan uji [33].

Tabel 2.1 merangkum posisi penelitian ini terhadap penelitian terdahulu.

Tabel 2.1 Matriks Posisi Penelitian terhadap Penelitian Terdahulu

Penelitian	**Objek**	**Pembanding HAR**	**Evaluasi sepanjang waktu**	**Variasi strategi window**	**Asosiasi dengan kondisi pasar**
Dudek dkk. [16]	RV 4 kripto, uji 2019–2021	Ya	Tidak (agregat)	Tidak (satu skema rolling)	Deskriptif, tanpa uji
Huang dkk. [15]	RV Bitcoin, uji $\pm$290 hari	Ya	Tidak (agregat)	Tidak	Tidak
Feng, Qi & Lucey [29]	RV BTC/USD, 2017–2022	Ya	Kepentingan fitur antarperiode	Hanya panjang rolling (uji ketahanan)	Tidak
Brauneis & Sahiner [18]	RV 6 jam 8 kripto, 2021–2022	Ya	Tidak (agregat)	Tidak	Tidak
Kılıç [19]	RV S&P 500, uji 2006–2023	Ya (+ HAR nonlinear)	Deskriptif per tahun	Tidak (expanding tahunan)	Tidak
Trucíos & Taylor [25]	VaR/ES BTC dan ETH	Tidak (model ekonometrik)	Ya (Fluctuation test)	Tidak	Tidak
Akgun & Gulay [28]	Volatilitas BTC, ETH, BNB s.d. 2021	Tidak (GARCH dan *deep learning*)	Tidak	Ya (dilaporkan untuk GARCH)	Tidak
Chassot & Audrino [6]	RV 1.445 saham AS, 2015–2023	Ya	Tidak (grafik, tanpa uji)	Ya (untuk HAR; ML statis)	Tidak
Penelitian ini	RV BTC/USDT spot, 2018–2026	Ya, perlakuan setara	Ya (UDmax; Fluctuation test eksploratori)	Ya (static, expanding, rolling)	Ya (regresi dengan uji formal)

Sumber: diolah dari penelitian terdahulu

Berdasarkan Tabel 2.1, celah penelitian ini merupakan gabungan dari: (1) uji kestabilan kinerja relatif ML terhadap HAR-RV pada RV Bitcoin lintas era pasar, (2) dekomposisi sumber perbedaan kinerja, (3) asosiasi perubahan kinerja dengan karakteristik pasar dan pergeseran distribusi fitur, serta (4) interaksi strategi pembaruan model dengan era pasar, dengan perlakuan *window* yang setara bagi HAR-RV.

2.2. Landasan Teori

2.2.1. Bitcoin dan Evolusi Karakteristik Pasarnya

Bitcoin merupakan sistem uang elektronik *peer-to-peer* yang memungkinkan transaksi tanpa perantara lembaga keuangan [1]. Sejak diperdagangkan secara luas, pasar Bitcoin mengalami pendewasaan. Do membagi perkembangan tersebut ke dalam tiga era [2]. Era *niche* (2012–2016) didominasi pengguna awal dan spekulan perorangan. Era *transition* (2017–2020) ditandai partisipasi investor perorangan secara luas, kontrak berjangka CME, dan berkembangnya bursa seperti Binance. Era *institutional* (2021–2025) ditandai integrasi dengan keuangan tradisional, termasuk ETF spot Bitcoin sejak Januari 2024. Dari era ke era, RV turun tajam, volume naik, dan biaya transaksi turun. Respons *illiquidity* terhadap guncangan volatilitas juga lebih kecil dan lebih singkat pada era *institutional*. Data Do disambung dari dua bursa, yaitu Bitstamp (2012–Oktober 2019) dan Binance (November 2019–2025), sehingga perbandingan level antarera perlu dibaca dengan hati-hati.

Perubahan karakteristik ini tidak monoton. Efisiensi pasar berganti-ganti antara periode efisien dan tidak efisien [3], dan pola data yang pernah muncul dapat berulang kembali [31]. Penelitian ini memakai pembagian era dari Do hanya sebagai alat analisis, bukan sebagai masukan model.

2.2.2. Efisiensi Pasar dan Keterramalan Volatilitas

Hipotesis pasar efisien bentuk lemah menyatakan bahwa *return* tidak dapat diprediksi dari harga masa lalu [4]. Hasil pengujiannya pada Bitcoin beragam. Dengan data harian 2010–2019, pasar Bitcoin ditemukan mendekati efisien dan relatif stabil antartahun [4]. Dengan data 2016–2023, efisiensinya berganti-ganti antara periode efisien dan tidak efisien [3]. Pada era *institutional*, *return* Bitcoin

mendekati *random walk* [2]. Perbedaan ini sebagian disebabkan oleh perbedaan ukuran dan periode yang dipakai.

Keterramalan *return* berbeda dengan keterramalan volatilitas. Pasar yang efisien dalam *return* tetap dapat memiliki volatilitas yang terprediksi, karena besarnya perubahan harga cenderung bertahan: autokorelasi kuadrat dan nilai absolut *return* tetap tinggi hingga hitungan bulan [8]. Model HAR-RV memanfaatkan sifat ini dengan meregresikan volatilitas pada volatilitas masa lalunya. Karena itu, peningkatan efisiensi pasar tidak membuat peramalan volatilitas menjadi tidak bermakna.

2.2.3. Realized Variance sebagai Proksi Volatilitas

Misalkan $C_{t,i}$ adalah harga penutupan bar 5 menit ke-i pada hari t. Satu hari UTC terdiri atas 288 bar 5 menit, sehingga *return* logaritmik intraday didefinisikan sebagai

$$r_{t,i} = \ln\left(\frac{C_{t,i}}{C_{t,i-1}}\right), \qquad i = 1, \ldots, 288, \tag{2.1}$$

Realized variance harian merupakan

$$RV_t = \sum_{i=1}^{288} r_{t,i}^2. \tag{2.2}$$

Corsi mendefinisikan *realized volatility* sebagai akar dari besaran tersebut [8]. Penelitian ini menggunakan skala varians karena fungsi *loss* QLIKE dihitung pada skala varians [30].

Pemilihan RV sebagai proksi didasarkan pada rantai argumen berikut. Proksi volatilitas yang berisik, seperti kuadrat *return* harian, membuat model tampak buruk walaupun sebenarnya baik, sedangkan RV dari data intraday jauh lebih akurat [5]. Proksi yang berisik juga dapat mengacaukan urutan peringkat model, sehingga perbandingan model memerlukan fungsi *loss* yang robust terhadap derau proksi [30]. Liu, Patton, dan Sheppard menunjukkan bahwa pada 31 aset dari lima kelas aset, RV 5 menit sulit dikalahkan secara signifikan oleh lebih dari 400 estimator lain, dan estimator yang lebih rumit justru memburuk relatif terhadap RV 5 menit pada periode derau dan volatilitas tinggi [7]. Karena likuiditas dan volatilitas Bitcoin

berubah besar antarera [2], resolusi 5 menit dipilih sebagai pilihan yang aman di semua era.

2.2.4. Model Heterogeneous Autoregressive (HAR-RV)

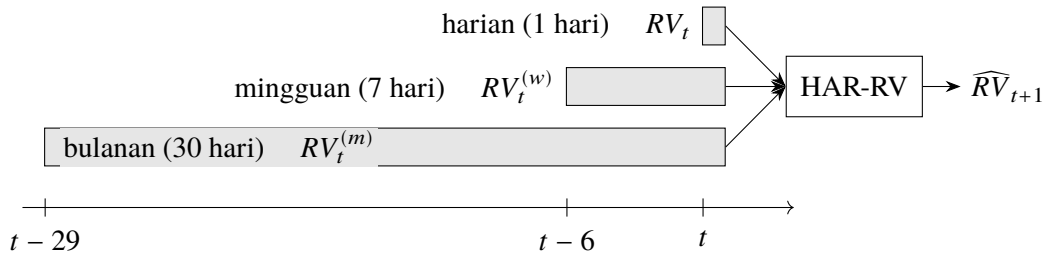
Model HAR-RV didasarkan pada gagasan bahwa pelaku pasar memiliki horizon waktu yang berbeda, misalnya harian, mingguan, dan bulanan, sehingga volatilitas dipengaruhi oleh komponen volatilitas dari ketiga horizon tersebut [8]. Meskipun berbentuk regresi linear sederhana, model ini mampu meniru sifat memori panjang volatilitas. Dengan rata-rata RV mingguan dan bulanan

$$RV_t^{(w)} = \frac{1}{7}\sum_{j=0}^{6} RV_{t-j}, \qquad RV_t^{(m)} = \frac{1}{30}\sum_{j=0}^{29} RV_{t-j}, \tag{2.3}$$

model HAR-RV dalam bentuk logaritma yang digunakan pada penelitian ini merupakan

$$\ln RV_{t+1} = \beta_0 + \beta_d \ln RV_t + \beta_w \ln RV_t^{(w)} + \beta_m \ln RV_t^{(m)} + \varepsilon_{t+1}. \tag{2.4}$$

Corsi membentuk rata-rata mingguan dan bulanan dari 5 dan 22 hari [8], sesuai jumlah hari perdagangan pasar saham. Bitcoin diperdagangkan setiap hari tanpa libur, sehingga horizon mingguan dan bulanan disesuaikan menjadi 7 dan 30 hari [9]; lag 5 dan 22 hari dipakai sebagai uji sensitivitas. Dalam evaluasi *out-of-sample*, Corsi mengestimasi ulang model setiap hari pada jendela bergerak 1.000 observasi [8], sedangkan kinerja relatif model peramalan dapat berubah sepanjang waktu [26]. Hal ini menjadi salah satu alasan stabilitas kinerja perlu diuji. Gambar 2.1 mengilustrasikan ketiga komponen tersebut.



Gambar 2.1 Ilustrasi Komponen Harian, Mingguan, dan Bulanan pada Model HAR-RV

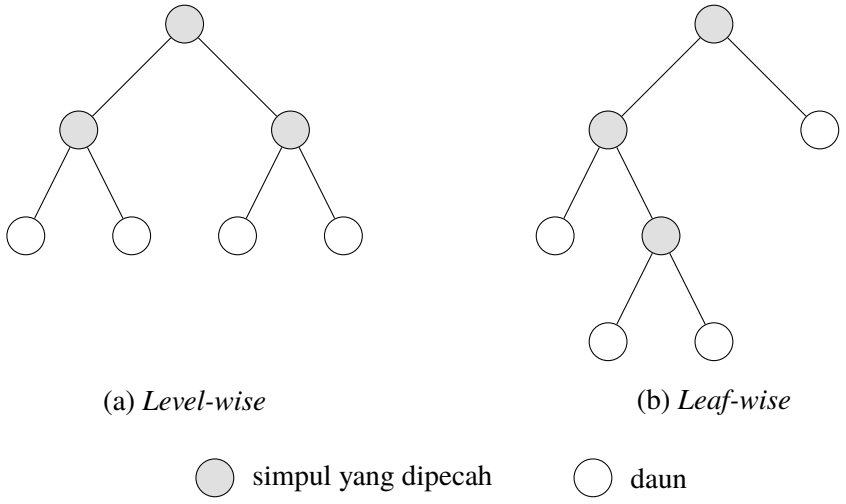
Sumber: diolah dari Corsi [8]

2.2.5. LightGBM

Gradient boosting decision tree (GBDT) membangun model prediksi sebagai penjumlahan berurutan pohon keputusan, dengan setiap pohon baru dilatih untuk mengoreksi kesalahan gabungan pohon-pohon sebelumnya. Secara umum, model pada iterasi ke-b adalah

$$F_b(\mathbf{x}) = F_{b-1}(\mathbf{x}) + \eta\, h_b(\mathbf{x}), \tag{2.5}$$

dengan η laju pembelajaran dan h_b pohon ke-b. LightGBM merupakan implementasi GBDT berbasis histogram yang dilengkapi dua teknik, yaitu *Gradient-based One-Side Sampling* (GOSS) dan *Exclusive Feature Bundling* (EFB), sehingga pelatihannya jauh lebih cepat dengan akurasi yang hampir sama dengan implementasi GBDT lain [11]. LightGBM menumbuhkan pohon secara *leaf-wise*, yaitu memecah daun dengan penurunan *loss* terbesar, berbeda dari pertumbuhan *level-wise* yang memecah seluruh daun pada kedalaman yang sama (Gambar 2.2). Pada jumlah daun yang sama, pertumbuhan *leaf-wise* umumnya mencapai *loss* lebih rendah, tetapi dapat mengalami *overfitting* pada data berukuran kecil [34]. Karena itu, jumlah daun (`num_leaves`) dan jumlah minimum data per daun (`min_data_in_leaf`) menjadi parameter utama untuk mengendalikan kompleksitas pohon [35].



Gambar 2.2 Pertumbuhan Pohon *Level-wise* dan *Leaf-wise*
Sumber: Digambar ulang, diadaptasi dari dokumentasi LightGBM [34]

LightGBM dipilih dengan tiga pertimbangan. Pertama, LightGBM dirancang untuk mempercepat pelatihan GBDT dengan akurasi yang hampir sama [11]. Sifat ini praktis karena model dalam penelitian ini dilatih ulang setiap bulan untuk beberapa skema pembaruan dan panjang *window*. Akurasinya juga hampir sama dengan XGBoost [11], [36], sehingga pilihan di antara keduanya bukan inti penelitian. Kedua, pada data tabular berukuran menengah (sekitar 10 ribu sampel), model berbasis pohon seperti *random forest* dan XGBoost konsisten mengungguli *deep learning*, bahkan setelah *tuning* dengan anggaran besar [12]. Benchmark tersebut memakai data i.i.d., sedangkan data latih penelitian ini berupa fitur lag deret waktu sebanyak 365 hingga sekitar 2.900 baris. Karena itu, temuan tersebut dipakai sebagai dasar pemilihan kelas model, bukan jaminan kinerja. Ketiga, LightGBM banyak dipakai dalam peramalan. Pada kompetisi M5, semua metode teratas merupakan metode ML dan LightGBM dipakai oleh tim-tim teratas, walaupun keunggulan tersebut didukung oleh banyak deret yang saling berkaitan dan data tambahan [13]. Penelitian ini juga mengikuti arahan untuk menggunakan ML non-*deep learning*.

Model berbasis pohon tidak selalu unggul pada kondisi ekstrem. Pada volatilitas tinggi, *random forest* dan LSTM termasuk model yang paling tidak akurat, walaupun perbandingan tersebut hanya deskriptif [16], dan XGBoost mengalami penurunan kinerja paling parah pada krisis 2008 [19]. Karena itu, kekalahan model berbasis pohon pada hari lonjakan volatilitas merupakan kemungkinan yang perlu diantisipasi.

2.2.6. Fitur Berbasis Data Intraday

Selain tiga komponen HAR, penelitian ini menggunakan fitur tambahan (fitur X) yang seluruhnya diturunkan dari data OHLCV. Pada empat aset kripto, determinan internal pasar, seperti lag volatilitas dan informasi perdagangan, merupakan prediktor terpenting volatilitas [10].

Realized semivariance negatif mengukur bagian variasi yang berasal dari *return* negatif [37]:

$$RS_t^- = \sum_{i=1}^{288} r_{t,i}^2 \, \mathbf{1}(r_{t,i} < 0). \tag{2.6}$$

Patton dan Sheppard menunjukkan bahwa *semivariance* negatif lebih informatif untuk meramal volatilitas pada saham [38]. Karena $RV_t = RS_t^- + RS_t^+$, fitur yang digunakan yaitu proporsi RS_t^- / RV_t agar tidak menimbulkan kolinearitas sempurna dengan komponen HAR.

Estimator *range* Parkinson memanfaatkan harga tertinggi P_t^H dan terendah P_t^L dalam satu hari [39]:

$$\sigma_{P,t}^2 = \frac{(\ln P_t^H - \ln P_t^L)^2}{4 \ln 2}. \tag{2.7}$$

Estimator ini mengasumsikan perdagangan kontinu, asumsi yang lebih terpenuhi pada Bitcoin yang diperdagangkan 24 jam sehari dibanding saham.

Ukuran *illiquidity* Amihud mengukur dampak harga per satuan volume transaksi [40]. Mengikuti Do [2], ukuran ini dihitung dalam versi *realized* dari bar 5 menit:

$$\text{Amihud}_t = 10^6 \cdot \frac{1}{N_t} \sum_i \frac{|r_{t,i}|}{QV_{t,i}}, \tag{2.8}$$

Amihud diperlakukan sebagai proksi dampak harga, bukan biaya transaksi [40], [41]. Fitur lainnya yaitu *return* harian, logaritma volume dolar, dan perubahan logaritma volume.

2.2.7. Fungsi Loss untuk Evaluasi Peramalan Volatilitas

Karena volatilitas sebenarnya tidak teramati, evaluasi peramalan menggunakan proksi RV. Patton menunjukkan bahwa hanya kelas fungsi *loss* tertentu yang menghasilkan peringkat model yang konsisten ketika proksi yang digunakan berisik; dua anggota kelas tersebut yaitu MSE dan QLIKE [30]. Untuk ramalan F_t dan proksi RV_t:

$$L_t^{\text{QLIKE}} = \frac{RV_t}{F_t} - \ln \frac{RV_t}{F_t} - 1, \qquad L_t^{\text{MSE}} = (RV_t - F_t)^2. \tag{2.9}$$

QLIKE homogen berderajat nol, artinya nilainya tidak berubah bila RV_t dan F_t dikalikan konstanta yang sama, sehingga *loss* tidak otomatis membesar hanya karena volatilitas sedang tinggi. QLIKE juga memberikan daya uji Diebold–Mariano–West yang lebih tinggi daripada MSE [30]. Karena itu QLIKE digunakan sebagai *loss*

utama dan MSE sebagai pelengkap. Dari bentuk Persamaan (2.9), QLIKE juga menghukum ramalan yang terlalu rendah lebih berat daripada ramalan yang terlalu tinggi. Ramalan optimal di bawah kedua *loss* tersebut merupakan nilai harapan kondisional [30].

Objek analisis penelitian ini merupakan selisih *loss* harian

$$\Delta L_t = L_t(\mathrm{ML}) - L_t(\mathrm{HAR}), \tag{2.10}$$

Nilai ΔL_t yang negatif menunjukkan model ML lebih akurat pada hari tersebut. Karena kedua model dievaluasi pada hari dan proksi yang sama, ΔL_t lebih sebanding antarperiode daripada *loss* masing-masing model, terutama bila memakai QLIKE.

2.2.8. Uji Perbandingan Akurasi Peramalan

Uji Diebold–Mariano (DM) menguji apakah dua ramalan memiliki akurasi yang sama, dengan hipotesis nol $E[\Delta L_t] = 0$. Fungsi *loss* yang dipakai tidak harus kuadratik maupun simetris, dan galat ramalan boleh berautokorelasi [42]. Statistik ujinya adalah

$$DM = \frac{\overline{\Delta L}}{\sqrt{\widehat{V}_{\mathrm{HAC}}/n}}, \tag{2.11}$$

Penelitian ini menggunakan estimator Newey–West [43] dengan *bandwidth* yang dipilih otomatis menurut Andrews [44].

Ketika sejumlah uji dijalankan sekaligus, peluang menemukan hasil signifikan secara kebetulan meningkat. Prosedur Holm mengendalikan peluang tersebut dengan mengurutkan *p-value* dan membandingkannya dengan ambang yang makin longgar secara bertahap [45]. Penelitian ini menetapkan uji konfirmatori untuk setiap hipotesis sebelum melihat hasil *out-of-sample*. Hipotesis H2b terdiri atas dua uji sehingga *p-value*-nya dikoreksi dengan prosedur Holm, sedangkan uji lain diperlakukan sebagai eksploratori dengan koreksi Holm.

2.2.9. Instabilitas Kinerja Peramalan dan Uji Perubahan Struktural

Uji DM membandingkan akurasi rata-rata pada seluruh periode uji. Ketika lingkungan berubah, kinerja relatif dua model dapat berbeda dari satu subperiode ke subperiode lain, dan rata-rata keseluruhan dapat menyembunyikan perubahan

tersebut [26]. Konsep ini perlu dibedakan dari *forecast breakdown*, yaitu kondisi ketika *loss out-of-sample* sebuah model secara signifikan lebih buruk daripada *loss in-sample*-nya [46]. Penelitian ini berfokus pada perubahan kinerja **relatif** antarmodel, bukan pada kerusakan satu model.

Fluctuation test dari Giacomini dan Rossi menghitung statistik DM secara bergulir pada jendela berukuran $n_F = \mu n$ dan membandingkannya dengan nilai kritis khusus yang memperhitungkan pengujian berulang [23]. Uji ini menunjukkan kapan satu model lebih unggul, tetapi hipotesis nolnya merupakan kedua model sama akurat di setiap titik waktu, bukan bahwa kinerja relatifnya stabil. Kerangka uji tersebut juga mensyaratkan skema estimasi *rolling* atau *fixed*; skema *expanding* hanya tersedia melalui versi West [23]. Martins dan Perron menunjukkan bahwa daya uji *Fluctuation test* rendah dan tidak monoton setelah koreksi HAC, dan mengusulkan penggunaan uji perubahan struktural pada rata-rata selisih *loss* [24].

Uji perubahan struktural Bai–Perron menguji keberadaan perubahan rata-rata ΔL_t pada titik waktu yang tidak diketahui [47]. Dengan $\sup F_T(m)$ adalah statistik F terbesar atas semua kemungkinan penempatan m titik patah, statistik UDmax didefinisikan sebagai

$$\text{UDmax} = \max_{1 \le m \le M} \sup F_T(m), \tag{2.12}$$

Statistik ini menguji hipotesis nol tanpa perubahan melawan alternatif adanya satu hingga M perubahan. Setiap segmen dibatasi minimal sebesar proporsi *trimming* ε dari sampel. Bai dan Perron menganjurkan UDmax dijalankan lebih dahulu; bila menolak, jumlah titik patah ditentukan dengan uji berurutan $\sup F(\ell + 1 \mid \ell)$ [48]. Penelitian ini menggunakan UDmax sebagai uji konfirmatori kestabilan dan *Fluctuation test* sebagai visualisasi eksploratori.

2.2.10. Evaluasi Out-of-Sample dan Strategi Pembaruan Model

Evaluasi model peramalan deret waktu harus menghormati urutan waktu. Tashman menekankan pentingnya evaluasi *out-of-sample* dengan banyak titik asal peramalan, dan membedakan *updating*, yaitu memasukkan data baru tanpa mengestimasi ulang parameter, dari *recalibration*, yaitu mengestimasi ulang parameter dengan data terbaru [21]. Validasi silang acak tidak cocok untuk deret

waktu karena memutus urutan waktu. Untuk deret yang tidak stasioner, estimasi kinerja paling akurat diperoleh dari metode *out-of-sample* berurutan, misalnya *prequential in blocks* dengan *window* yang bertambah atau bergeser [49].

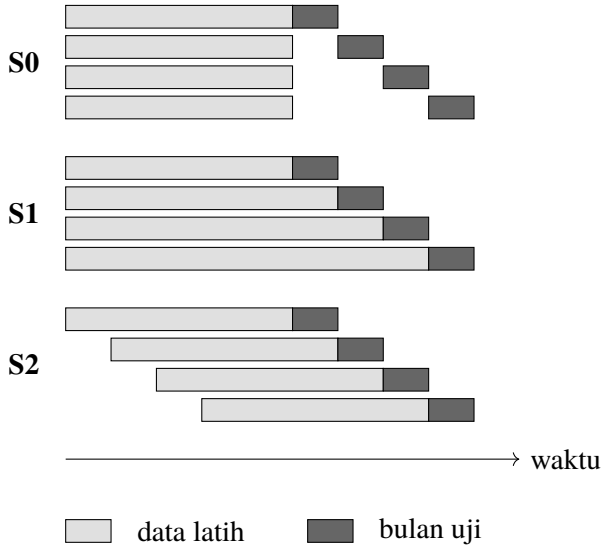
Dalam literatur *concept drift*, cara model beradaptasi terhadap data yang berubah dikelompokkan antara lain berdasarkan pengelolaan *window* data latih [22]. *Window* yang tumbuh (*expanding*) menyimpan seluruh histori, sedangkan *window* geser berukuran tetap (*rolling*) hanya memakai data terbaru. *Window* pendek cepat beradaptasi ketika pola berubah, tetapi memperburuk kinerja ketika pola stabil; *window* panjang sebaliknya [22]. Model yang tidak pernah dilatih ulang berfungsi sebagai pembanding untuk mengukur manfaat adaptasi [50]. Tabel 2.2 dan Gambar 2.3 merangkum ketiga strategi yang digunakan.

Tabel 2.2 Strategi Pembaruan Model dan Padanannya dalam Literatur

Kode	Strategi	Data latih	Padanan dalam literatur
S0	Static	Dilatih sekali pada window awal, tidak dilatih ulang	*Updating* tanpa rekalibrasi [21]; pembanding manfaat adaptasi [50]
S1	Expanding	Dilatih ulang bulanan dengan seluruh data yang tersedia	*Growing window* pada *prequential in blocks* [49]
S2	Rolling	Dilatih ulang bulanan dengan W hari terakhir, $W \in \{365, 730\}$; uji konfirmatori memakai $W = 365$ (S2-365)	*Sliding window* [22], [49]

Sumber: rancangan penelitian, diolah dari literatur

Pilihan strategi melibatkan *trade-off* bias dan varians. Menyertakan data sebelum perubahan struktural menambah bias tetapi dapat mengurangi varians kesalahan ramalan, sehingga memakai sebagian data tersebut dapat optimal selama perubahannya tidak terlalu besar [51]. Secara umum, *rolling window* cenderung lebih baik ketika perubahan besar dan berulang, sedangkan skema rekursif (*expanding*) lebih baik ketika perubahan kecil atau tidak ada. Untuk model autoregresif seperti HAR, data sebelum perubahan bahkan dapat mengurangi bias dan varians sekaligus [26]. Pilihan *window* pada perbandingan ML dengan HAR juga harus setara, karena HAR yang diberi skema *fitting* yang kurang tepat dapat membuat ML tampak unggul secara semu [6]. Selain itu, skema *rolling* menyamakan panjang data latih antarperiode [21] dan sesuai dengan syarat kerangka



Gambar 2.3 Skema Strategi Pembaruan Model Static, Expanding, dan Rolling
Sumber: rancangan penelitian

uji Giacomini–Rossi [23], sehingga uji formal kestabilan dijalankan pada skema *rolling*.

2.2.11. Pergeseran Distribusi Data

Pergeseran data (*dataset shift*) terjadi ketika distribusi bersama masukan dan target pada data uji berbeda dari data latih [52]. Literatur menggunakan istilah yang berbeda untuk jenis perubahan yang sama, seperti dirangkum pada Tabel 2.3.

Tabel 2.3 Perbandingan Istilah Pergeseran Data menurut Gama dkk. dan Moreno-Torres dkk.

Perubahan	**Gama dkk. [22]**	**Moreno-Torres dkk. [52]**
$P(x)$ berubah	*Virtual drift* (tanpa syarat mengenai $P(y \mid x)$)	*Covariate shift* (dengan syarat $P(y \mid x)$ tetap)
$P(y \mid x)$ berubah	*Real concept drift* ($P(x)$ boleh berubah)	*Concept shift* (dengan syarat $P(x)$ tetap)

Sumber: diolah dari Gama dkk. [22] dan Moreno-Torres dkk. [52]

Peramalan RV termasuk masalah $X \rightarrow Y$, karena fitur hari t mendahului target hari $t+1$, sehingga kerangka Moreno-Torres dkk. yang relevan [52]. Penelitian ini hanya mengukur perubahan distribusi fitur $P(x)$ dan tidak menguji apakah $P(y \mid x)$ tetap. Oleh karena itu istilah yang dipakai yaitu **pergeseran distribusi fitur**, bukan *covariate shift* atau *concept drift* dalam arti formal.

Pergeseran distribusi satu fitur antara data latih dan bulan uji diukur dengan statistik Kolmogorov–Smirnov dua sampel,

$$D^{\mathrm{KS}} = \sup_{x} \left| \hat{F}_{\mathrm{latih}}(x) - \hat{F}_{\mathrm{uji}}(x) \right|, \tag{2.13}$$

Nilai D^{KS} merupakan jarak terbesar antara kedua fungsi distribusi kumulatif empiris. Uji KS per fitur merupakan salah satu pendekatan sederhana untuk mendeteksi pergeseran data dan menjadi pembanding yang kompetitif terhadap metode yang lebih kompleks [53]. Berbeda dari penggunaan sebagai uji hipotesis, penelitian ini tidak memakai *p-value*-nya. Nilai D^{KS} dirata-ratakan antarfitur sebagai ukuran besaran pergeseran per bulan.

2.2.12. Proksi Likuiditas

Likuiditas pasar kripto dapat diukur dengan berbagai proksi berbasis data harga dan volume. Brauneis dkk. menunjukkan bahwa proksi yang paling baik menangkap variasi likuiditas kripto antarwaktu berbeda dengan proksi yang paling baik menangkap levelnya: estimator *spread* Abdi–Ranaldo [54] unggul untuk variasi waktu, sedangkan ukuran Amihud unggul untuk level [41]. Karena itu, penelitian ini memakai Amihud sebagai fitur model LGBM-X dan estimator Abdi–Ranaldo, yang dihitung dari harga OHLC harian, sebagai variabel likuiditas dalam analisis asosiasi kinerja relatif dengan kondisi pasar, dengan estimator Corwin–Schultz [55] sebagai uji sensitivitas. Amihud tidak disertakan pada HAR-X karena berkolinearitas tinggi dengan komponen HAR berdasarkan pemeriksaan pada *window* awal; rinciannya diuraikan pada Bab III. Proksi likuiditas harian juga dipakai Zhang dkk. untuk mengkaji hubungan antara *return* dan likuiditas aset kripto [56].

2.3. Kerangka Pemikiran

Kerangka pemikiran penelitian ini berangkat dari dua fakta. Pertama, karakteristik pasar Bitcoin berubah lintas era [2], [3]. Kedua, perbandingan model ML dengan HAR-RV umumnya dilaporkan sebagai satu hasil agregat [15], [16], padahal kinerja relatif dapat berubah sepanjang waktu [22], [26]. Dari kedua fakta tersebut, penelitian ini menanyakan apakah kinerja relatif LightGBM terhadap HAR-RV stabil, faktor pasar apa yang berasosiasi dengan perubahannya, dan bagaimana strategi pembaruan model memengaruhinya.

Untuk menjawabnya, perbedaan kinerja diurai melalui desain 2 × 2 pada Tabel 2.4. Perbandingan LGBM-HAR dengan HAR mengukur kontribusi non-linearitas, perbandingan HAR-X dengan HAR mengukur kontribusi informasi tambahan, dan perbandingan LGBM-X dengan HAR mengukur kontribusi total. Model *naive persistence* ($\widehat{RV}_{t+1} = RV_t$) disertakan sebagai pemeriksaan kewajaran.

Tabel 2.4 Desain Perbandingan Model 2 × 2

	Masukan HAR	**Masukan HAR + fitur X**
Linear	HAR-RV (pembanding)	HAR-X
Non-linear	LGBM-HAR	LGBM-X

Sumber: rancangan penelitian

Pada HAR-X, fitur X tidak mencakup ukuran Amihud (lihat Subbab 2.2.12).

Alur kerangka pemikiran ditunjukkan pada Gambar 2.4.

2.4. Hipotesis Penelitian

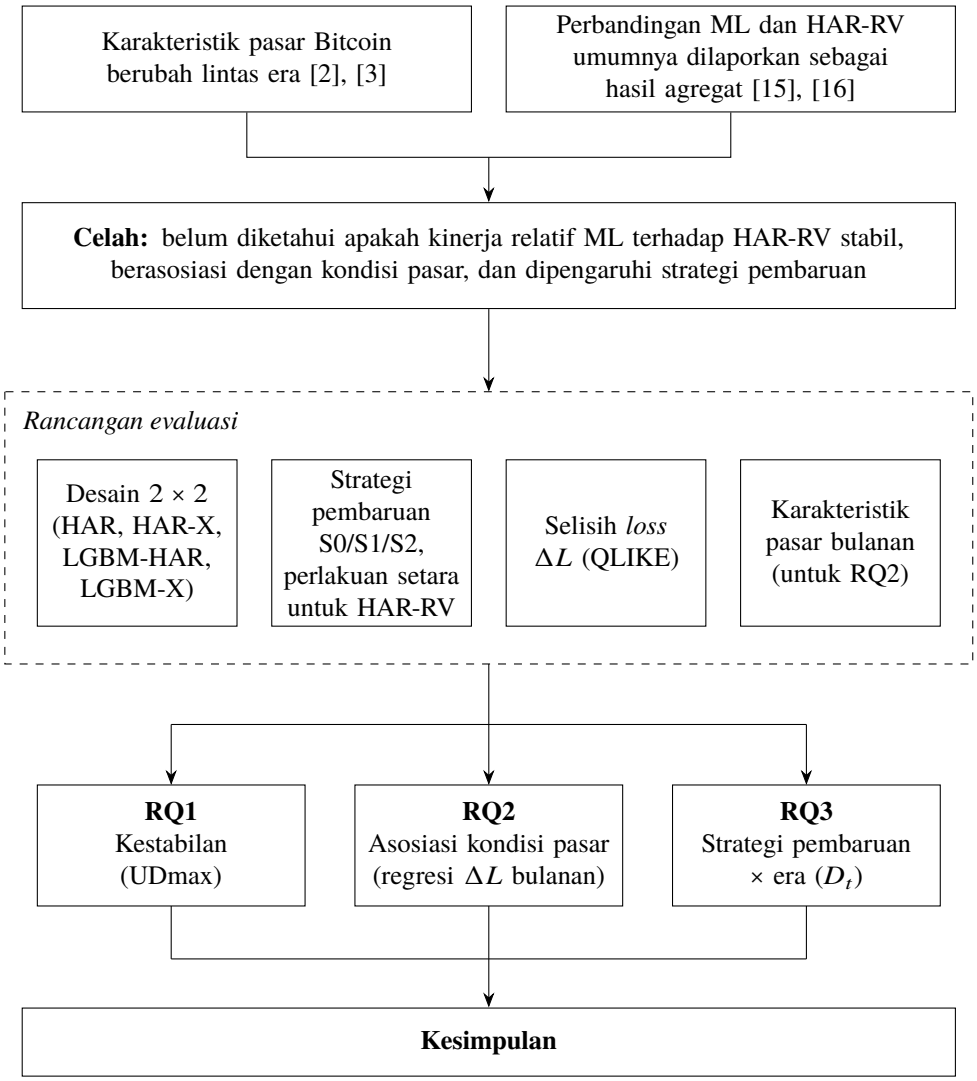
Berdasarkan landasan teori di atas, hipotesis penelitian dirumuskan sebagai berikut.

H1. Rata-rata selisih *loss* ΔL(LGBM-X − HAR) tidak konstan sepanjang periode pengujian. Hipotesis ini diturunkan dari perubahan karakteristik pasar Bitcoin lintas era [2], [3] dan dari literatur instabilitas peramalan [24], [26].

H2a. Selisih *loss* bulanan berasosiasi dengan sedikitnya satu karakteristik pasar, yaitu level volatilitas, volatilitas dari volatilitas, likuiditas, atau pergeseran distribusi fitur. Pendekatan meregresikan ukuran kinerja peramalan pada indikator yang teramati mengikuti semangat Giacomini dan Rossi [46].

H2b. Kontribusi fitur X terhadap kinerja relatif berbeda antara era *transition* dan *institutional*. Do menunjukkan bahwa hubungan volatilitas–likuiditas berubah antarera [2], tetapi Do menguji arah volatilitas terhadap *illiquidity*, sedangkan penelitian ini memakai likuiditas dan volume untuk meramal RV; H2b merupakan perluasan dari temuan tersebut. Mokni dkk. menunjukkan hubungan likuiditas dapat berbalik tanda [3], dan kepentingan fitur tidak konsisten antarstudi [10], [29]. Karena itu H2b dirumuskan dua arah.

H3. Pada era *institutional*, kinerja relatif LGBM-X terhadap HAR-RV lebih baik pada strategi *rolling* 365 hari (S2-365) dibandingkan *expanding* (S1). Dengan $D_t = \Delta L_t(\text{S2-365}) - \Delta L_t(\text{S1})$, dan ΔL_t adalah selisih *loss* LGBM-X



Gambar 2.4 Kerangka Pemikiran Penelitian

Sumber: rancangan penelitian

terhadap HAR-RV pada Persamaan 2.10, H3 didukung bila rata-rata D_t negatif dan signifikan. Hipotesis ini didasarkan pada *trade-off* bias–varians [26], [51] dan perubahan karakteristik pasar antarera [2]: hubungan yang dipelajari dari era awal dapat usang, dan LGBM-X yang lebih fleksibel diduga lebih terdampak data usang daripada HAR.

Hipotesis tandingan. Hasil yang berlawanan dengan H3 tetap bermakna. Data sebelum perubahan struktural dapat tetap berguna [51]. Untuk model autoregresif, data sebelum perubahan struktural dapat mengurangi bias dan varians sekaligus, sehingga skema *expanding* dapat lebih baik daripada *rolling* [26]. Selain itu, bila *regime* volatilitas berulang, data lama tetap relevan [22], [31].

Ringkasan rumusan masalah, hipotesis, dan uji konfirmatorinya disajikan pada Tabel 2.5. Uji konfirmatori ditetapkan sebelum hasil *out-of-sample* dilihat.

Tabel 2.5 Ringkasan Rumusan Masalah, Hipotesis, dan Uji Konfirmatori

Rumusan masalah	**Hipotesis**	**Uji konfirmatori**
RQ1 Kestabilan kinerja relatif	H1	UDmax pada rata-rata ΔL(LGBM-X − HAR), skema rolling 365 hari, QLIKE, HAC, $\varepsilon = 0{,}15$, maksimum 5 perubahan; bila tidak menolak, uji DM pada seluruh sampel
RQ2 Asosiasi dengan kondisi pasar	H2a, H2b	H2a: uji-F bersama (HAC) pada regresi ΔL bulanan terhadap 4 karakteristik pasar. H2b: dua uji-t HAC beda rata-rata antara era *transition* dan *institutional*, untuk ΔL(HAR-X − HAR) dan ΔL(LGBM-X − LGBM-HAR), dengan koreksi Holm
RQ3 Strategi pembaruan × era	H3	Uji-t HAC dua sisi pada rata-rata $D_t = \Delta L_t$(S2-365) − ΔL_t(S1) pasangan LGBM-X dan HAR-RV di era *institutional*

Sumber: rancangan penelitian

BAB III
METODOLOGI

Bab ini menguraikan rancangan penelitian yang digunakan untuk menjawab ketiga rumusan masalah pada Subbab 1.2, meliputi jenis dan alur penelitian, data, rancangan model dan skema pembaruan, contoh perhitungan, serta rancangan evaluasi dan pengujian hipotesis.

3.1. Metode Penelitian

Penelitian ini merupakan penelitian kuantitatif eksperimental dengan data sekunder deret waktu. Objek yang dievaluasi merupakan kinerja relatif model LightGBM terhadap model HAR-RV dalam meramalkan *realized variance* harian BTC/USDT spot satu hari ke depan. Penelitian bersifat implementatif: seluruh tahapan, mulai dari pengolahan data, pelatihan model, hingga pengujian statistik, diimplementasikan sebagai satu *pipeline* perangkat lunak yang dapat dijalankan ulang.

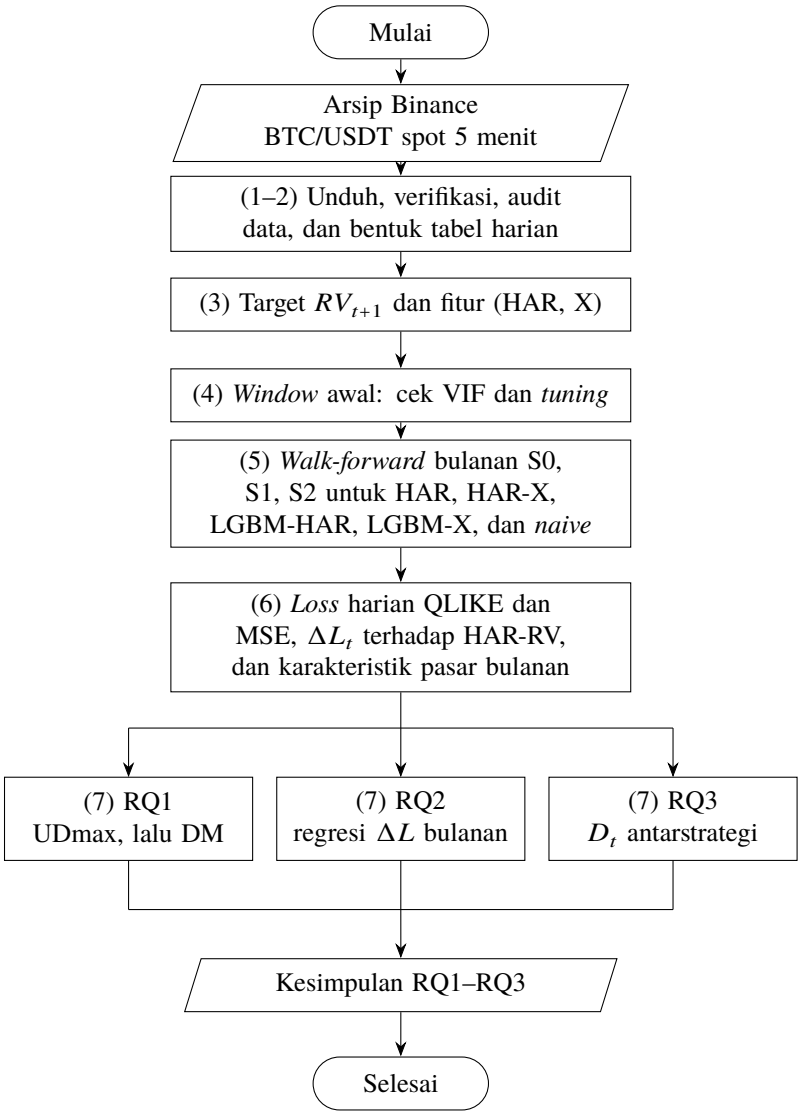
Strategi penelitian berupa eksperimen komputasional dengan evaluasi *out-of-sample* secara *walk-forward*. Subjek penelitian merupakan data harga BTC/USDT pasar spot, yang merupakan data sekunder dan tersedia secara publik, sehingga penelitian tidak terikat pada lokasi fisik tertentu. Data dikumpulkan dengan mengunduh arsip publik Binance (Subbab 3.2.1), sedangkan analisis dilakukan dengan membandingkan selisih *loss* harian antarmodel dan mengujinya secara statistik (Subbab 3.4). Peralatan yang digunakan diuraikan pada Subbab 3.1.3.

Seluruh keputusan desain, termasuk pasangan model, skema, fungsi *loss*, dan uji konfirmatori untuk setiap hipotesis (Tabel 2.5), ditetapkan dalam satu berkas konfigurasi sebelum hasil *out-of-sample* pasangan konfirmatori dilihat. Nilai *hash* berkas konfigurasi dicatat pada setiap keluaran sehingga perubahan desain setelah hasil diketahui dapat terdeteksi. Prinsip ini mencegah pemilihan uji atau hipotesis berdasarkan hasil.

3.1.1. Alur Penelitian

Alur penelitian ditunjukkan pada Gambar 3.1 dan terdiri atas tahapan berikut: (1) pengunduhan data dan verifikasi *checksum*; (2) audit dan pembentukan

tabel harian; (3) pembentukan target dan fitur; (4) pemeriksaan kolinearitas dan *tuning hyperparameter* pada *window* awal; (5) peramalan *walk-forward* untuk setiap skema pembaruan dan model; (6) perhitungan *loss* harian, selisih *loss*, dan karakteristik pasar bulanan; (7) pengujian hipotesis konfirmatori dan analisis eksploratori untuk RQ1–RQ3.



Gambar 3.1 Alur Penelitian

Sumber: rancangan penelitian

3.1.2. Tahap Uji Kelayakan

Sebelum desain dikunci, dilakukan tahap uji kelayakan dengan pasangan eksploratori LGBM-HAR dan HAR-RV. Tahap ini memeriksa kelengkapan data, kebenaran *pipeline*, kolinearitas fitur, prosedur *tuning*, dan daya uji. Pasangan

konfirmatori LGBM-X terhadap HAR-RV tidak dievaluasi secara *out-of-sample* pada tahap tersebut, dan hasil uji kelayakan tidak digunakan untuk mengubah rumusan masalah, hipotesis, maupun uji konfirmatori.

3.1.3. Peralatan Penelitian

Implementasi menggunakan bahasa Python 3.12 dengan pustaka `pandas`, `numpy`, `lightgbm` versi 4, `scikit-learn`, `statsmodels`, `scipy`, dan `matplotlib`. Estimator kovarians HAC diimplementasikan sendiri mengikuti kernel Bartlett dengan *bandwidth* otomatis Andrews [44] dan diverifikasi menghasilkan nilai yang identik dengan fungsi `kernHAC` paket R `sandwich`. Seluruh pelatihan memakai *seed* tetap (42) dan mode deterministik LightGBM.

3.2. Desain Sistem

3.2.1. Data

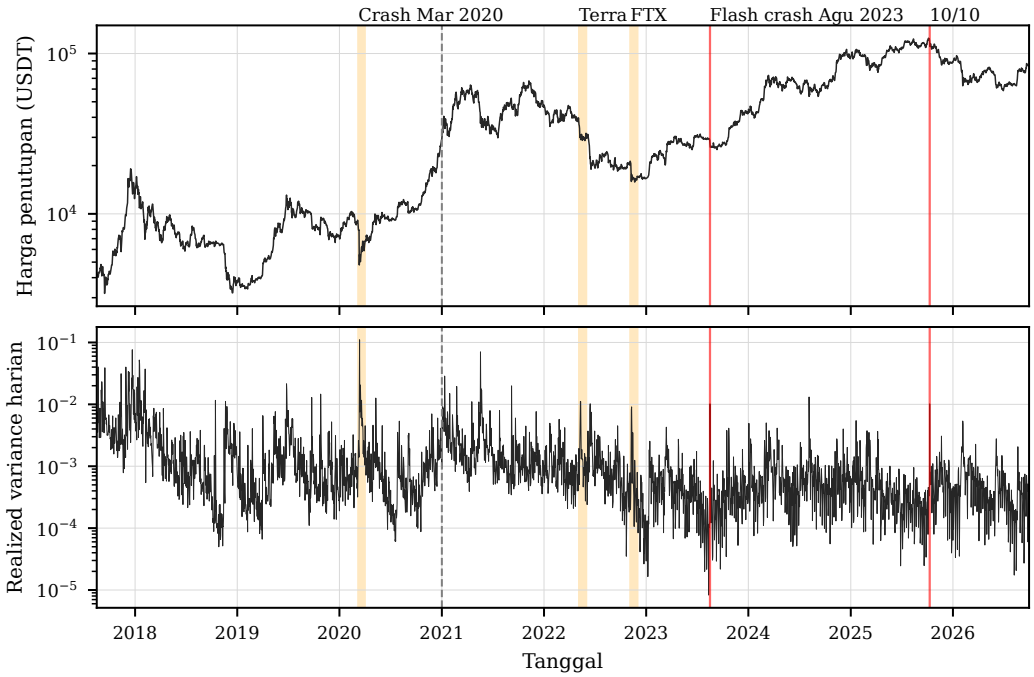
Data yang digunakan merupakan *klines* (OHLCV) BTC/USDT pasar spot dengan resolusi 5 menit dari arsip publik Binance (`data.binance.vision`), diunduh per bulan dan diverifikasi dengan *checksum* SHA-256 resmi. Periode data adalah 17 Agustus 2017, yaitu awal ketersediaan arsip, hingga 30 September 2026. Tanggal awal yang sama juga digunakan pada penelitian peramalan risiko aset kripto dengan data Binance [25]. Kolom yang digunakan adalah harga pembukaan, tertinggi, terendah, penutupan, serta *quote asset volume* (volume dalam USDT) sebagai volume dolar. Ringkasan data ditunjukkan pada Tabel 3.1 dan pergerakannya pada Gambar 3.2.

Tabel 3.1 Ringkasan Data Penelitian

Komponen	**Keterangan**
Sumber	Binance Public Data, folder *spot*, simbol berkas BTCUSDT
Resolusi	5 menit (288 bar per hari UTC)
Periode	17 Agustus 2017 – 30 September 2026
Jumlah bar	957.865
Jumlah hari	3.332
Hari dengan bar < 95%	27 (dibuang, Subbab 3.2.2)
Hari dengan $RV = 0$	0

Sumber: data Binance, diolah

Pemilihan pasar spot didasarkan pada tiga alasan: histori spot tersedia sejak 2017 sementara kontrak *perpetual* baru sejak sekitar September 2019, padahal RQ3 membutuhkan data era awal; harga *perpetual* mengandung efek *funding rate*, likuidasi, dan basis; serta keterbandingan dengan literatur [16]. Penggunaan satu bursa sepanjang periode juga mencegah perubahan antarera tercampur dengan efek pergantian sumber data, berbeda dengan Do yang berganti dari Bitstamp ke Binance pada November 2019 [2]. Resolusi 5 menit dipilih sebagai kompromi yang aman lintas era likuiditas (Subbab 2.2.3) [7], dan resolusi yang sama digunakan pada penelitian volatilitas kripto sebelumnya [9], [16], [29].



Gambar 3.2 Harga Penutupan dan *Realized Variance* Harian BTC/USDT Spot, 17 Agustus 2017–30 September 2026

Sumber: data Binance, diolah

Keterangan: garis putus-putus menandai batas era *transition* dan *institutional* (1 Januari 2021) mengikuti Do [2]; arsir menandai *crash* Maret 2020, Terra (Mei 2022), dan FTX (November 2022); garis merah menandai *flash crash* 17 Agustus 2023 dan 10 Oktober 2025 (“10/10”). Sumbu vertikal berskala logaritmik.

3.2.2. Audit dan Pra-pemrosesan Data

Tahapan audit adalah sebagai berikut.

1. **Standarisasi *timestamp*.** Arsip Binance sejak 1 Januari 2025 mencatat waktu dalam mikrodetik, sedangkan arsip sebelumnya dalam milidetik; seluruh *timestamp* diseragamkan ke milidetik UTC, lalu duplikat dibuang dan data diurutkan.
2. **Kelengkapan hari.** Hari dengan jumlah bar kurang dari 95% (kurang dari 274 dari 288 bar) ditandai tidak lengkap. Pasangan observasi (fitur hari t, target hari $t+1$) dibuang bila hari t **atau** hari $t+1$ tidak lengkap atau memiliki RV nol. Sebanyak 27 hari ditandai tidak lengkap. Sebagai uji sensitivitas, hari-hari tersebut dipertahankan.
3. **Hari ekstrem dipertahankan** dan tidak dipangkas, karena lonjakan volatilitas justru bagian dari fenomena yang diteliti.
4. **Volume nol.** Bar dengan volume dolar nol dikecualikan dari perhitungan Amihud (Persamaan (2.8)).

3.2.3. Target dan Fitur

Target peramalan merupakan RV_{t+1} (Persamaan (2.2)); model dilatih pada $\ln RV_{t+1}$ lalu ramalannya dikembalikan ke skala level (Subbab 3.2.5). Seluruh fitur hari t hanya memakai data hingga akhir hari t. Tiga puluh hari pertama digunakan sebagai periode pemanasan untuk rata-rata bulanan. Horizon mingguan dan bulanan HAR ditetapkan 7 dan 30 hari, menyesuaikan perdagangan aset kripto yang berlangsung 24 jam setiap hari [9]. Fitur dan model yang memakainya ditunjukkan pada Tabel 3.2.

Tabel 3.2 Fitur dan Model Pemakainya

Fitur	**Definisi**	**Dipakai oleh**
$\ln RV_t$, $\ln RV_t^{(w)}$, $\ln RV_t^{(m)}$	Persamaan (2.3), rata-rata 1, 7, 30 hari	semua model
Proporsi semivarians negatif	RS_t^- / RV_t, Persamaan (2.6)	HAR-X, LGBM-X
Return harian	$\ln(C_t / C_{t-1})$	HAR-X, LGBM-X
Log volume dolar	$\ln \sum_i QV_{t,i}$	HAR-X, LGBM-X
Perubahan log volume dolar	selisih log volume dolar hari t dan $t-1$	HAR-X, LGBM-X
Log *range* Parkinson	$\ln \sigma^2_{P,t}$, Persamaan (2.7)	HAR-X, LGBM-X
Log Amihud	$\ln \text{Amihud}_t$, Persamaan (2.8)	LGBM-X

Sumber: rancangan penelitian

Kolinearitas diperiksa dengan *variance inflation factor* (VIF) pada *window* awal, sebelum fitur dikunci. Log Amihud (VIF 19,6) dan log volume dolar (VIF 18,2) menunjukkan kolinearitas tinggi; secara konstruksi log Amihud mendekati setengah $\ln RV$ dikurangi log volume dolar. Sesuai aturan yang ditetapkan sebelumnya, log Amihud dibuang dari HAR-X saja, sehingga VIF maksimum fitur X pada HAR-X menjadi 6,9. LGBM-X tetap memakai kesembilan fitur karena model pohon tidak mengestimasi koefisien regresi, sehingga kolinearitas tidak menimbulkan ketidakstabilan estimasi seperti pada OLS.

3.2.4. Model

Model yang digunakan mengikuti desain 2 × 2 pada Tabel 2.4, ditambah model *naive persistence* $\widehat{RV}_{t+1} = RV_t$ sebagai pemeriksaan kewajaran.

- **HAR-RV dan HAR-X** diestimasi dengan *ordinary least squares* (OLS) pada $\ln RV_{t+1}$ (Persamaan (2.4)); HAR-X menambahkan fitur X sebagai regresor.
- **LGBM-HAR dan LGBM-X** menggunakan LightGBM [11] dengan *objective* regresi kuadrat, *bagging* 80% data per pohon, dan *hyperparameter* hasil *tuning* (Subbab 3.2.6). Penelitian ini menggunakan mode *boosting* standar LightGBM dengan *bagging* sebagai regularisasi; GOSS dan EFB yang dirancang untuk mempercepat pelatihan pada data besar dan fitur jarang tidak berperan karena data latih hanya berisi ratusan hingga ribuan baris dengan sembilan fitur padat. Dengan `num_leaves` = 3, setiap pohon hanya memiliki dua pemecahan sehingga perbedaan pertumbuhan *leaf-wise* dan *level-wise* praktis hilang.
- **Random Forest** [57], yaitu rata-rata banyak pohon regresi yang masing-masing dilatih pada sampel *bootstrap* dengan pemilihan fitur acak di setiap pemisahan, dengan masukan yang sama dengan LGBM-X (300 pohon, minimum 20 observasi per daun, 33% fitur per pemisahan) digunakan hanya sebagai uji sensitivitas jenis model pohon.

3.2.5. Aturan Teknis Peramalan

Aturan berikut berlaku sama untuk semua model.

1. **Koreksi bias transformasi log.** Karena ramalan optimal di bawah QLIKE dan MSE merupakan nilai harapan kondisional [30], $\exp(\hat{y})$ tanpa koreksi akan sistematis terlalu rendah. Ramalan dikoreksi menjadi $\exp(\hat{y}_{t+1} + \hat{\sigma}^2/2)$.

Nilai $\hat{\sigma}^2$ adalah varians residual model yang dilatih pada 80% awal *window* latih, dihitung pada 20% akhir *window*; setelah itu model dilatih ulang pada seluruh *window*. Residual *in-sample* tidak dipakai karena LightGBM cenderung *overfit*.

2. **Batas bawah ramalan.** Ramalan dibatasi minimal sebesar persentil ke-1 target *RV* pada *window* latih, $\underline{F}$, karena QLIKE menghukum ramalan yang terlalu rendah jauh lebih berat.

   Ramalan akhir adalah

$$F_{t+1} = \max\left\{\exp\left(\hat{y}_{t+1} + \tfrac{1}{2}\hat{\sigma}^2\right),\ \underline{F}\right\}. \tag{3.1}$$

Sebagai uji sensitivitas, koreksi bias ditiadakan.

3.2.6. *Tuning Hyperparameter*

Hyperparameter LightGBM dituning **sekali** pada *window* awal (Agustus 2017 – Agustus 2018), lalu dikunci untuk seluruh periode pengujian. Validasi silang acak tidak digunakan karena memutus urutan waktu [49]. *Tuning* dilakukan dengan validasi berurutan waktu (*forward-chaining*) lima lipatan, yaitu setiap lipatan dilatih pada data sebelum lipatan validasinya. Parameter `num_leaves` dan `min_child_samples` (nama lain `min_data_in_leaf`) merupakan parameter utama untuk mengendalikan kompleksitas pohon dan mencegah *overfitting* [35], sedangkan `reg_lambda` merupakan penalti L2 terhadap bobot daun [36]. Metrik pemilihan adalah rata-rata QLIKE ramalan $\exp(\hat{y})$ antarlipatan. Bila kombinasi terbaik berada di tepi ruang pencarian untuk `min_child_samples` atau `n_estimators`, ruang pencarian diperluas satu langkah ke arah tepi tersebut, maksimal dua kali, dengan batas bawah `min_child_samples` sebesar 5 untuk menjaga regularisasi. Ruang pencarian dan nilai terkunci ditunjukkan pada Tabel 3.3.

Nilai `min_child_samples` = 5 pada LGBM-X merupakan batas bawah ruang pencarian yang ditetapkan sebelumnya, sehingga dicatat sebagai keputusan desain untuk menjaga regularisasi.

Tabel 3.3 Ruang Pencarian dan *Hyperparameter* Terkunci

Parameter	Ruang pencarian awal	LGBM-HAR	LGBM-X
`num_leaves`	3, 7, 15	3	3
`min_child_samples`	10, 20, 40, 80	10	5
`n_estimators`	50, 100, 300, 600	300	300
`learning_rate`	0,03	0,03	0,03
`reg_lambda`	1, 10	1	1

Sumber: rancangan penelitian

3.2.7. Skema Pembaruan Model (*Walk-Forward*)

Peramalan dilakukan secara *walk-forward* bulanan: pada awal setiap bulan uji, model dilatih ulang (kecuali S0) menggunakan data dengan tanggal target sebelum bulan tersebut, lalu meramalkan setiap hari dalam bulan itu. Ketiga strategi utama mengikuti Tabel 2.2 dan Gambar 2.3. Model HAR-RV memakai strategi dan *window* yang sama dengan model ML pada setiap sel perbandingan [6]. Awal periode *out-of-sample* setiap skema ditunjukkan pada Tabel 3.4; perbandingan antarskema selalu dilakukan pada periode bersama.

Tabel 3.4 Skema Pembaruan dan Awal Periode *Out-of-Sample*

Skema	Data latih	Awal OOS	Peran
S0	*Window* awal, tidak dilatih ulang	1 Sep 2018	pembanding manfaat adaptasi
S1	Seluruh data tersedia (*expanding*)	1 Sep 2018	utama (RQ3)
S2-365	365 hari terakhir	1 Sep 2018	utama (RQ1, RQ2, RQ3)
S2-730	730 hari terakhir	1 Sep 2019	eksploratori
S2-180	180 hari terakhir	1 Sep 2018	eksploratori
S2-1095	1.095 hari terakhir	1 Sep 2020	eksploratori
Tertunda-365	hari ke-730 s.d. ke-365 sebelum bulan uji	1 Sep 2019	eksploratori (umur data)

Sumber: rancangan penelitian

Pembagian era mengikuti Do [2], dengan batas 1 Januari 2021 antara era *transition* dan *institutional*; data tahun 2026 diperlakukan sebagai kelanjutan era *institutional* dan diuji sensitivitasnya. Batas era hanya digunakan dalam analisis, tidak sebagai fitur model.

3.2.8. Kontrol Kebocoran Data

Langkah pencegahan kebocoran informasi masa depan:

1. fitur hari t hanya memakai data hingga akhir hari t, sedangkan target adalah hari $t + 1$;
2. *tuning* hanya dilakukan pada *window* awal dengan validasi berurutan waktu, bukan validasi silang acak [49];
3. $\hat{\sigma}^2$ dan batas bawah $\underline{F}$ dihitung hanya dari *window* latih;
4. batas era tidak digunakan sebagai fitur;
5. tidak ada ambang atau label yang dibentuk dengan melihat data *out-of-sample*.

3.3. Perhitungan Manual

Subbab ini memberikan contoh perhitungan satu kali peramalan untuk model HAR-RV dan LGBM-HAR. Agar tidak memuat hasil pengujian, contoh diambil dari *window* awal: hari $t^* = 30$ Agustus 2018 digunakan untuk meramalkan RV tanggal 31 Agustus 2018, dengan 339 observasi latih (tanggal target 16 September 2017 s.d. 30 Agustus 2018). Seluruh angka ditulis dengan enam digit bermakna dan telah dicocokkan dengan keluaran implementasi.

3.3.1. *Realized Variance* dan Komponen HAR

Return bar pertama hari t^* dihitung terhadap harga penutupan bar terakhir 29 Agustus 2018, yaitu 7.031,22. Lima bar pertama ditunjukkan pada Tabel 3.5.

Tabel 3.5 Lima Bar Pertama Hari t^* dan Komponennya

Waktu (UTC)	Penutupan	$r_{t,i}$	$r_{t,i}^2$	$r_{t,i} < 0$
00:00	7.038,22	$9{,}95065 \times 10^{-4}$	$9{,}90153 \times 10^{-7}$	tidak
00:05	7.036,24	$-2{,}81361 \times 10^{-4}$	$7{,}91638 \times 10^{-8}$	ya
00:10	7.031,41	$-6{,}86682 \times 10^{-4}$	$4{,}71532 \times 10^{-7}$	ya
00:15	7.039,17	$1{,}10301 \times 10^{-3}$	$1{,}21663 \times 10^{-6}$	tidak
00:20	7.039,01	$-2{,}27302 \times 10^{-5}$	$5{,}16662 \times 10^{-10}$	ya

Sumber: hasil perhitungan

Penjumlahan kuadrat *return* atas 288 bar (Persamaan (2.2)) menghasilkan $RV_{t^*} = 5{,}37199 \times 10^{-4}$. Sebanyak 154 bar memiliki *return* negatif, sehingga $RS^-_{t^*} = 2{,}67476 \times 10^{-4}$ (Persamaan (2.6)) dan proporsinya $RS^-_{t^*}/RV_{t^*} = 0{,}497908$.

Komponen HAR dihitung dari rata-rata RV harian, mingguan, dan bulanan (Persamaan (2.3)) seperti pada Tabel 3.6.

Tabel 3.6 Komponen HAR pada Hari t^*

Komponen	Nilai
RV 24 Agustus 2018	$6{,}28396 \times 10^{-4}$
RV 25 Agustus 2018	$3{,}50138 \times 10^{-4}$
RV 26 Agustus 2018	$4{,}82313 \times 10^{-4}$
RV 27 Agustus 2018	$4{,}99351 \times 10^{-4}$
RV 28 Agustus 2018	$4{,}54143 \times 10^{-4}$
RV 29 Agustus 2018	$4{,}40669 \times 10^{-4}$
RV 30 Agustus 2018 ($= RV_{t^*}$)	$5{,}37199 \times 10^{-4}$
Rata-rata mingguan $RV_{t^*}^{(w)}$	$4{,}84601 \times 10^{-4}$
Bulanan (30 nilai, 1–30 Agustus 2018): minimum	$3{,}50138 \times 10^{-4}$
maksimum	$3{,}80630 \times 10^{-3}$
Rata-rata bulanan $RV_{t^*}^{(m)}$	$1{,}27306 \times 10^{-3}$
$\ln RV_{t^*}$	−7,52914
$\ln RV_{t^*}^{(w)}$	−7,63218
$\ln RV_{t^*}^{(m)}$	−6,66633

Sumber: hasil perhitungan

3.3.2. Fitur X

Keenam fitur X pada hari t^* ditunjukkan pada Tabel 3.7. Model HAR-X tidak memakai log Amihud, sesuai hasil pemeriksaan VIF pada Subbab 3.2.3; fitur tersebut hanya dipakai LGBM-X.

Tabel 3.7 Fitur X pada Hari t^*

Fitur	Masukan mentah	Hasil
Return harian	penutupan t^* = 6.984,84; penutupan $t^* - 1$ = 7.031,22	−0,00661815
Log volume dolar	volume dolar $t^* = 3{,}09357 \times 10^8$	19,5500
Perubahan log volume dolar	volume dolar $t^* - 1 = 3{,}04565 \times 10^8$	19,5500 − 19,5344 = 0,0156107
Log *range* Parkinson	$P_{t^*}^H$ = 7.063,63; $P_{t^*}^L$ = 6.784,81	−7,44394
Log Amihud	$10^6\times$ rata-rata $\lvert r_{t,i}\rvert / QV_{t,i}$ = 0,00116494	−6,75508
Proporsi semivarians negatif	lihat Subbab 3.3.1	0,497908

Sumber: hasil perhitungan

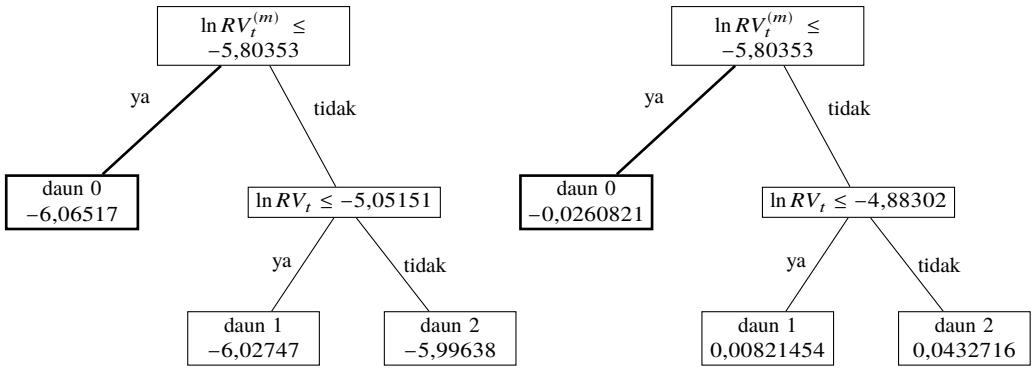
3.3.3. Peramalan HAR-RV dan LGBM-HAR

Koefisien HAR-RV hasil OLS pada *window* latih adalah $\beta_0 = -0{,}569890$, $\beta_d = 0{,}478542$, $\beta_w = 0{,}0689003$, dan $\beta_m = 0{,}384379$. Dengan Persamaan (2.4),

$$\begin{aligned}\hat{y}_{t^*+1} &= (-0{,}569890) + (0{,}478542)(-7{,}52914) + (0{,}0689003)(-7{,}63218) \\ &\quad + (0{,}384379)(-6{,}66633) \\ &= (-0{,}569890) + (-3{,}60301) + (-0{,}525859) + (-2{,}56240) \\ &= -7{,}26116. \end{aligned} \tag{3.2}$$

Varians residual $\hat{\sigma}^2 = 0{,}497938$ diperoleh dari model yang dilatih pada 271 observasi awal dan dievaluasi pada 68 observasi akhir. Dengan Persamaan (3.1), $\exp(-7{,}26116 + 0{,}248969) = 9{,}00836 \times 10^{-4}$, yang berada di atas batas bawah $\underline{F} = 2{,}90955 \times 10^{-4}$, sehingga $F_{\text{HAR}} = 9{,}00836 \times 10^{-4}$.

Pada LGBM-HAR, nilai awal berupa rata-rata $\ln RV_{t+1}$ data latih, $-6{,}03756$, dilebur ke nilai daun pohon pertama, sehingga $\hat{y}$ merupakan jumlah nilai daun dari 300 pohon (Persamaan (2.5)). Struktur dua pohon pertama beserta lintasan hari t^* ditunjukkan pada Gambar 3.3.



(a) Pohon ke-1 (b) Pohon ke-2

Gambar 3.3 Struktur Pohon ke-1 dan ke-2 LGBM-HAR pada Contoh Perhitungan

Sumber: hasil perhitungan

Pada Gambar 3.3, garis tebal menandai lintasan hari t^*. Hari tersebut memiliki $\ln RV_{t^*}^{(m)} = -6{,}66633$, yang memenuhi syarat pemisahan pertama pada kedua pohon, sehingga keduanya berakhir di daun 0. Kontribusi pohon ke-1 adalah $-6{,}06517$, yaitu gabungan nilai awal $-6{,}03756$ dan nilai daun $-0{,}0276166$;

kontribusi pohon ke-2 adalah $-0{,}0260821$; dan jumlah kontribusi pohon ke-3 hingga ke-300 adalah $-1{,}22919$. Total ketiganya menghasilkan $\hat{y}_{t^*+1} = -7{,}32044$. Dengan $\hat{\sigma}^2 = 0{,}511547$, diperoleh $\exp(-7{,}32044 + 0{,}255773) = 8{,}54778 \times 10^{-4}$, yang juga di atas batas bawah, sehingga $F_{\text{LGBM}} = 8{,}54778 \times 10^{-4}$.

3.3.4. Evaluasi Satu Hari

Realized variance aktual tanggal 31 Agustus 2018 adalah $4{,}14190 \times 10^{-4}$. Nilai *loss* kedua model dihitung dengan Persamaan (2.9) dan ditunjukkan pada Tabel 3.8.

Tabel 3.8 Evaluasi Ramalan 31 Agustus 2018

Model	F_{t+1}	RV_{t+1}/F_{t+1}	**QLIKE**	**MSE**
HAR-RV	$9{,}00836 \times 10^{-4}$	0,459784	0,236783	$2{,}36825 \times 10^{-7}$
LGBM-HAR	$8{,}54778 \times 10^{-4}$	0,484558	0,209076	$1{,}94118 \times 10^{-7}$

Sumber: hasil perhitungan

Selisih *loss* pada hari tersebut (Persamaan (2.10)) adalah $\Delta L = 0{,}209076 - 0{,}236783 = -0{,}0277067$. Nilai negatif menunjukkan LGBM-HAR lebih akurat **pada hari contoh ini saja**; satu hari tidak dapat dijadikan dasar kesimpulan, sehingga pengujian dilakukan atas seluruh periode *out-of-sample* sebagaimana diuraikan pada Subbab 3.4.

3.4. Evaluasi dan Pengujian Hipotesis

3.4.1. Fungsi *Loss* dan Selisih *Loss*

Setiap ramalan dievaluasi dengan QLIKE sebagai *loss* utama dan MSE pada skala level sebagai pelengkap (Persamaan (2.9)). Objek analisis merupakan selisih *loss* harian ΔL_t (Persamaan (2.10)). Pasangan konfirmatori merupakan LGBM-X terhadap HAR-RV pada skema S2-365; pasangan lain, yaitu LGBM-HAR–HAR, HAR-X–HAR, LGBM-X–LGBM-HAR, dan LGBM-X–HAR-X, digunakan untuk dekomposisi secara eksploratori.

3.4.2. Uji Konfirmatori

Uji konfirmatori setiap hipotesis mengikuti Tabel 2.5. Rincian pelaksanaannya adalah sebagai berikut.

1. **H1.** UDmax (Persamaan (2.12)) pada rata-rata ΔL_t dengan *trimming* $\varepsilon = 0{,}15$ dan maksimum lima perubahan, statistik Wald memakai kovarians HAC

[24], [47], [48]. Bila UDmax tidak menolak H_0, dilanjutkan dengan uji tipe Diebold–Mariano (Persamaan (2.11)) pada seluruh sampel.

2. **H2a.** Diuji dengan regresi rata-rata ΔL bulanan pada empat karakteristik pasar (Subbab 3.4.3), dengan uji-F bersama berbasis kovarians HAC.
3. **H2b.** Diuji dengan regresi $\Delta L_t = \alpha + \delta\,\mathrm{Era}_t + e_t$ untuk dua pasangan kontribusi fitur X (HAR-X–HAR dan LGBM-X–LGBM-HAR), uji-t HAC pada δ, dengan koreksi Holm atas dua uji tersebut [45].
4. **H3.** Uji-t HAC dua sisi pada rata-rata D_t (Subbab 2.4) di era *institutional*, pada periode bersama S2-365 dan S1. H3 didukung bila rata-rata D_t negatif dan signifikan; rata-rata positif yang signifikan dibaca sebagai dukungan bagi hipotesis tandingan.

Semua uji menggunakan taraf signifikansi 5% dan kovarians HAC Newey–West dengan kernel Bartlett dan *bandwidth* otomatis Andrews [43], [44].

Nilai kritis UDmax, uji perubahan berurutan, dan *Fluctuation test* diperoleh dengan simulasi Monte Carlo, bukan dikutip dari tabel: 3.000 replikasi deret normal baku sepanjang 1.000 observasi untuk UDmax, dan 5.000 replikasi gerak Brown diskret untuk *Fluctuation test*. *p-value* dihitung sebagai $(R^+ + 1)/(R + 1)$, dengan R^+ jumlah statistik simulasi yang tidak lebih kecil dari statistik amatan dan R jumlah replikasi. Nilai kritis simulasi dibandingkan dengan tabel Bai–Perron sebagai pemeriksaan [47].

3.4.3. Variabel Karakteristik Pasar (RQ2)

Untuk setiap bulan uji dihitung empat variabel seperti pada Tabel 3.9.

Tabel 3.9 Variabel Karakteristik Pasar Bulanan

Variabel	Definisi
Level volatilitas	rata-rata $\ln RV_t$ dalam bulan
Volatilitas dari volatilitas	deviasi standar $\ln RV_t$ dalam bulan
Likuiditas	rata-rata *spread* Abdi–Ranaldo harian [54]
Pergeseran distribusi fitur	rata-rata D^{KS} (Persamaan (2.13)) antara *window* latih S2-365 dan bulan uji atas sembilan fitur LGBM-X; dipakai sebagai besaran, bukan sebagai keputusan uji

Sumber: rancangan penelitian

Spread Abdi–Ranaldo harian dihitung sebagai

$$s_t = \sqrt{\max\{4\,(c_t - \bar{p}_t)(c_t - \bar{p}_{t+1}),\, 0\}}, \tag{3.3}$$

dengan $\bar{p}_t = (\ln P_t^H + \ln P_t^L)/2$ dan c_t logaritma harga penutupan hari t. Nilai negatif di bawah akar dijadikan nol sebelum dirata-rata. Estimator ini merupakan versi dua hari terkoreksi (*two-day corrected*) yang kemudian dirata-ratakan per bulan [54]. Perhitungan likuiditas memakai seluruh hari dalam bulan, termasuk hari yang ditandai tidak lengkap pada Subbab 3.2.2. Sebagai uji sensitivitas, estimator Corwin–Schultz [55] digunakan sebagai pengganti; penyesuaian harga *overnight* pada estimator tersebut tidak diperlukan karena BTC/USDT diperdagangkan 24 jam tanpa jeda. Sebagai pelengkap deskriptif, dihitung pula *population stability index* (PSI) antara *window* latih dan bulan uji.

Regresi H2a dirumuskan sebagai

$$\overline{\Delta L}_\tau = \alpha + \sum_{k=1}^{4} \gamma_k\, z_{k,\tau} + \delta\, \mathrm{Era}_\tau + u_\tau, \tag{3.4}$$

dengan $\overline{\Delta L}_\tau$ rata-rata ΔL_t bulan τ, $z_{k,\tau}$ keempat variabel pada Tabel 3.9, dan Era_τ variabel *dummy* era *institutional* yang selalu disertakan. Untuk menghindari regresi palsu, setiap regresor diuji dengan ADF [58] dan KPSS [59]; regresor di-*differencing* bila ADF gagal menolak akar unit ($p > 0{,}05$) **dan** KPSS menolak stasioneritas ($p < 0{,}05$), yaitu kombinasi hasil yang menunjukkan adanya akar unit [59]. Hipotesis yang diuji adalah $\gamma_1 = \gamma_2 = \gamma_3 = \gamma_4 = 0$. Interpretasi bersifat asosiatif, bukan kausal.

3.4.4. Analisis Eksploratori

Analisis berikut bersifat eksploratori dan *p-value*-nya dikoreksi dengan prosedur Holm per keluarga rumusan masalah [45]:

1. uji perubahan berurutan $\sup F(\ell + 1 \mid \ell)$ untuk menentukan jumlah dan tanggal perubahan [48];
2. *Fluctuation test* dengan $\mu = 0{,}3$ dan $0{,}2$ sebagai grafik deskriptif [23];
3. pasangan dekomposisi, skema S0 dan S2 lain, serta *loss* MSE;

4. kurva panjang *window* (S2-180 s.d. S1) dan perbandingan efek jumlah data (S2-730 terhadap S2-365) dengan efek umur data (Tertunda-365 terhadap S2-365);
5. analisis daya UDmax dengan *bootstrap* blok 30 hari.

3.4.5. Uji Sensitivitas

Kesimpulan konfirmatori diperiksa terhadap variasi pada Tabel 3.10.

Tabel 3.10 Variasi Uji Sensitivitas

Variasi	**Perubahan terhadap desain utama**
Tanpa 2026	data uji dibatasi hingga 31 Desember 2025
Hari tidak lengkap dipertahankan	aturan audit Subbab 3.2.2 butir 2 tidak diterapkan
Window awal 24 bulan	*tuning* dan awal OOS memakai *window* awal 730 hari
Lag 1, 5, 22	horizon HAR mengikuti hari perdagangan saham
Random Forest	LGBM-X diganti Random Forest
RV 15 menit	target dan fitur HAR dari *return* 15 menit
Tanpa koreksi bias	$\hat{\sigma}^2 = 0$ pada Persamaan (3.1)
HAR re-estimasi harian	HAR dilatih ulang setiap hari, bukan bulanan
Likuiditas Corwin–Schultz	khusus H2a

Sumber: rancangan penelitian

3.5. Jadwal Penelitian

Jadwal pelaksanaan penelitian ditunjukkan pada Tabel 3.11.

Tabel 3.11 Jadwal Penelitian

No	**Kegiatan**	**Bln 1**	**Bln 2**	**Bln 3**	**Bln 4**
1	Studi literatur dan verifikasi kebaruan				
2	Pengumpulan dan audit data				
3	Uji kelayakan (*pilot*)				
4	Implementasi *pipeline* dan eksperimen				
5	Analisis dan pengujian hipotesis				
6	Penulisan Bab IV dan V				
7	Seminar hasil dan sidang				

Sumber: rancangan penelitian

DAFTAR PUSTAKA

[1] S. Nakamoto. "Bitcoin: A Peer-to-Peer Electronic Cash System." (2008), Tersedia: https://bitcoin.org/bitcoin.pdf (Diakses 10/05/2026).

[2] K.-O. Do, "Maturation of Bitcoin market microstructure: Evidence of institutional-grade liquidity and efficiency (2012–2025)," *Borsa Istanbul Review*, vol. 26, no. 5, p. 100 869, 2026. DOI: 10.1016/j.bir.2026.100869.

[3] K. Mokni, G. El Montasser, A. N. Ajmi, dan E. Bouri, "On the efficiency and its drivers in the cryptocurrency market: the case of Bitcoin and Ethereum," *Financial Innovation*, vol. 10, no. 1, p. 39, 2024. DOI: 10.1186/s40854-023-00566-3.

[4] E. Yi, B. Yang, M. Jeong, S. Sohn, dan K. Ahn, "Market efficiency of cryptocurrency: evidence from the Bitcoin market," *Scientific Reports*, vol. 13, no. 1, p. 4789, 2023. DOI: 10.1038/s41598-023-31618-4.

[5] T. G. Andersen dan T. Bollerslev, "Answering the Skeptics: Yes, Standard Volatility Models Do Provide Accurate Forecasts," *International Economic Review*, vol. 39, no. 4, pp. 885–905, 1998. DOI: 10.2307/2527343.

[6] J. Chassot dan F. Audrino, "HARd to beat: The overlooked impact of rolling windows in the era of machine learning," *International Journal of Forecasting*, vol. 42, no. 2, pp. 330–343, 2026. DOI: 10.1016/j.ijforecast.2025.06.003.

[7] L. Y. Liu, A. J. Patton, dan K. Sheppard, "Does Anything Beat 5-Minute RV? A Comparison of Realized Measures across Multiple Asset Classes," *Journal of Econometrics*, vol. 187, no. 1, pp. 293–311, 2015. DOI: 10.1016/j.jeconom.2015.02.008.

[8] F. Corsi, "A Simple Approximate Long-Memory Model of Realized Volatility," *Journal of Financial Econometrics*, vol. 7, no. 2, pp. 174–196, 2009. DOI: 10.1093/jjfinec/nbp001.

[9] Y. Qiu, S. Qu, Z. Shi, dan T. Xie, "Predicting cryptocurrency volatility: The power of model clustering," *Economic Modelling*, vol. 144, p. 106 986, 2025. DOI: 10.1016/j.econmod.2024.106986.

[10] Y. Wang, G. Andreeva, dan B. Martin-Barragan, "Machine learning approaches to forecasting cryptocurrency volatility: Considering internal and external determinants," *International Review of Financial Analysis*, vol. 90, p. 102 914, 2023. DOI: 10.1016/j.irfa.2023.102914.

[11] G. Ke, Q. Meng, T. Finley, et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," dalam *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 3146–3154.

[12] L. Grinsztajn, E. Oyallon, dan G. Varoquaux, "Why Do Tree-Based Models Still Outperform Deep Learning on Typical Tabular Data?" Dalam *Advances in Neural Information Processing Systems*, vol. 35, 2022. arXiv: 2207.08815.

[13] S. Makridakis, E. Spiliotis, dan V. Assimakopoulos, "M5 accuracy competition: Results, findings, and conclusions," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1346–1364, 2022. DOI: 10.1016/j.ijforecast.2021.11.013.

[14] K. Christensen, M. Siggaard, dan B. Veliyev, "A Machine Learning Approach to Volatility Forecasting," *Journal of Financial Econometrics*, vol. 21, no. 5, pp. 1680–1727, 2023. DOI: 10.1093/jjfinec/nbac020.

[15] Z.-C. Huang, I. Sangiorgi, dan A. Urquhart, "Forecasting Bitcoin volatility using machine learning techniques," *Journal of International Financial Markets, Institutions and Money*, vol. 97, p. 102 064, 2024. DOI: 10.1016/j.intfin.2024.102064.

[16] G. Dudek, P. Fiszeder, P. Kobus, dan W. Orzeszko, "Forecasting cryptocurrencies volatility using statistical and machine learning methods: A comparative study," *Applied Soft Computing*, vol. 151, p. 111 132, 2024. DOI: 10.1016/j.asoc.2023.111132.

[17] G. Dudek, M. Kasprzyk, dan P. Pełka, *Multivariate Forecasting of Bitcoin Volatility with Gradient Boosting: Deterministic, Probabilistic, and Feature Importance Perspectives*, Preprint, 2025. arXiv: 2511.20105.

[18] A. Brauneis dan M. Sahiner, "Crypto Volatility Forecasting: Mounting a HAR, Sentiment, and Machine Learning Horserace," *Asia-Pacific Financial Markets*, vol. 33, no. 1, pp. 379–411, 2026. DOI: 10.1007/s10690-024-09510-6.

[19] R. Kılıç, "Linear and nonlinear econometric models against machine learning models: realized volatility prediction," Board of Governors of the Federal Reserve System, Finance and Economics Discussion Series 2025-061, 2025. DOI: 10.17016/feds.2025.061.

[20] V. Pyrlik, P. Elizarov, dan A. Leonova, "Forecasting Realized Volatility Using Machine Learning and Mixed-Frequency Data (the Case of the Russian Stock Market)," CERGE-EI, Working Paper 713, 2021. DOI: 10.2139/ssrn.3996169.

[21] L. J. Tashman, "Out-of-Sample Tests of Forecasting Accuracy: An Analysis and Review," *International Journal of Forecasting*, vol. 16, no. 4, pp. 437–450, 2000. DOI: 10.1016/S0169-2070(00)00065-0.

[22] J. Gama, I. Žliobaitė, A. Bifet, M. Pechenizkiy, dan A. Bouchachia, "A Survey on Concept Drift Adaptation," *ACM Computing Surveys*, vol. 46, no. 4, 44:1–44:37, 2014. DOI: 10.1145/2523813.

[23] R. Giacomini dan B. Rossi, "Forecast Comparisons in Unstable Environments," *Journal of Applied Econometrics*, vol. 25, no. 4, pp. 595–620, 2010. DOI: 10.1002/jae.1177.

[24] L. F. Martins dan P. Perron, "Improved Tests for Forecast Comparisons in the Presence of Instabilities," *Journal of Time Series Analysis*, vol. 37, no. 5, pp. 650–659, 2016. DOI: 10.1111/jtsa.12179.

[25] C. Trucíos dan J. W. Taylor, "A comparison of methods for forecasting value at risk and expected shortfall of cryptocurrencies," *Journal of Forecasting*, vol. 42, no. 4, pp. 989–1007, 2023. DOI: 10.1002/for.2929.

[26] B. Rossi, "Advances in Forecasting under Instability," dalam *Handbook of Economic Forecasting*, vol. 2, Elsevier, 2013, pp. 1203–1324. DOI: 10.1016/B978-0-444-62731-5.00021-X.

[27] Y. Feng, Y. Zhang, dan Y. Wang, "Out-of-sample volatility prediction: Rolling window, expanding window, or both?" *Journal of Forecasting*, vol. 43, no. 3, pp. 567–582, 2024. DOI: 10.1002/for.3046.

[28] O. B. Akgun dan E. Gulay, "Dynamics in Realized Volatility Forecasting: Evaluating GARCH Models and Deep Learning Algorithms Across Parameter Variations," *Computational Economics*, vol. 65, no. 6, pp. 3971–4013, 2025. DOI: 10.1007/s10614-024-10694-2.

[29] L. Feng, J. Qi, dan B. Lucey, "Enhancing cryptocurrency market volatility forecasting with daily dynamic tuning strategy," *International Review of Financial Analysis*, vol. 94, p. 103 239, 2024. DOI: 10.1016/j.irfa.2024.103239.

[30] A. J. Patton, "Volatility Forecast Comparison Using Imperfect Volatility Proxies," *Journal of Econometrics*, vol. 160, no. 1, pp. 246–256, 2011. DOI: 10.1016/j.jeconom.2010.03.034.

[31] A. L. Suárez-Cetrulo, D. Quintana, dan A. Cervantes, "A Survey on Machine Learning for Recurring Concept Drifting Data Streams," *Expert Systems with Applications*, vol. 213, p. 118 934, 2023. DOI: 10.1016/j.eswa.2022.118934.

[32] S.-V. Oprea dan A. Bâra, "Regime-Aware Adaptive Forecasting Framework for Bitcoin Prices Using Probabilistic Generative Models," *Computational Economics*, 2026, Online first. DOI: 10.1007/s10614-026-11338-3.

[33] I. Agakishiev, W. K. Härdle, D. Becker, dan X. Zuo, "Regime switching forecasting for cryptocurrencies," *Digital Finance*, vol. 7, no. 1, pp. 107–131, 2025. DOI: 10.1007/s42521-024-00123-2.

[34] Microsoft Corporation. "Features," LightGBM Documentation. (), Tersedia: https://lightgbm.readthedocs.io/en/v%3Cversi%3E/Features.html (Diakses 10/12/2026).

[35] Microsoft Corporation. "Parameters Tuning," LightGBM Documentation. (), Tersedia: https://lightgbm.readthedocs.io/en/stable/Parameters-Tuning.html (Diakses 10/12/2026).

[36] T. Chen dan C. Guestrin, "XGBoost: A Scalable Tree Boosting System," dalam *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794. DOI: 10.1145/2939672.2939785.

[37] O. E. Barndorff-Nielsen, S. Kinnebrock, dan N. Shephard, "Measuring Downside Risk: Realised Semivariance," dalam *Volatility and Time Series*

Econometrics: Essays in Honor of Robert F. Engle, Oxford: Oxford University Press, 2010, pp. 117–136.

[38] A. J. Patton dan K. Sheppard, "Good Volatility, Bad Volatility: Signed Jumps and the Persistence of Volatility," *The Review of Economics and Statistics*, vol. 97, no. 3, pp. 683–697, 2015. DOI: 10.1162/REST_a_00503.

[39] M. Parkinson, "The Extreme Value Method for Estimating the Variance of the Rate of Return," *The Journal of Business*, vol. 53, no. 1, pp. 61–65, 1980. DOI: 10.1086/296071.

[40] Y. Amihud, "Illiquidity and Stock Returns: Cross-Section and Time-Series Effects," *Journal of Financial Markets*, vol. 5, no. 1, pp. 31–56, 2002. DOI: 10.1016/S1386-4181(01)00024-6.

[41] A. Brauneis, R. Mestel, R. Riordan, dan E. Theissen, "How to Measure the Liquidity of Cryptocurrency Markets?" *Journal of Banking & Finance*, vol. 124, p. 106 041, 2021. DOI: 10.1016/j.jbankfin.2020.106041.

[42] F. X. Diebold dan R. S. Mariano, "Comparing Predictive Accuracy," *Journal of Business & Economic Statistics*, vol. 13, no. 3, pp. 253–263, 1995. DOI: 10.1080/07350015.1995.10524599.

[43] W. K. Newey dan K. D. West, "A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix," *Econometrica*, vol. 55, no. 3, pp. 703–708, 1987. DOI: 10.2307/1913610.

[44] D. W. K. Andrews, "Heteroskedasticity and Autocorrelation Consistent Covariance Matrix Estimation," *Econometrica*, vol. 59, no. 3, pp. 817–858, 1991. DOI: 10.2307/2938229.

[45] S. Holm, "A Simple Sequentially Rejective Multiple Test Procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.

[46] R. Giacomini dan B. Rossi, "Detecting and Predicting Forecast Breakdowns," *The Review of Economic Studies*, vol. 76, no. 2, pp. 669–705, 2009. DOI: 10.1111/j.1467-937X.2009.00545.x.

[47] J. Bai dan P. Perron, "Estimating and Testing Linear Models with Multiple Structural Changes," *Econometrica*, vol. 66, no. 1, pp. 47–78, 1998. DOI: 10.2307/2998540.

[48] J. Bai dan P. Perron, "Computation and Analysis of Multiple Structural Change Models," *Journal of Applied Econometrics*, vol. 18, no. 1, pp. 1–22, 2003. DOI: 10.1002/jae.659.

[49] V. Cerqueira, L. Torgo, dan I. Mozetič, "Evaluating Time Series Forecasting Models: An Empirical Study on Performance Estimation Methods," *Machine Learning*, vol. 109, no. 11, pp. 1997–2028, 2020. DOI: 10.1007/s10994-020-05910-7.

[50] I. Žliobaitė, M. Budka, dan F. Stahl, "Towards Cost-Sensitive Adaptation: When Is It Worth Updating Your Predictive Model?" *Neurocomputing*, vol. 150, pp. 240–249, 2015. DOI: 10.1016/j.neucom.2014.05.084.

[51] M. H. Pesaran dan A. Timmermann, "Selection of estimation window in the presence of breaks," *Journal of Econometrics*, vol. 137, no. 1, pp. 134–161, 2007.

[52] J. G. Moreno-Torres, T. Raeder, R. Alaiz-Rodríguez, N. V. Chawla, dan F. Herrera, "A Unifying View on Dataset Shift in Classification," *Pattern Recognition*, vol. 45, no. 1, pp. 521–530, 2012. DOI: 10.1016/j.patcog.2011.06.019.

[53] S. Rabanser, S. Günnemann, dan Z. C. Lipton, "Failing Loudly: An Empirical Study of Methods for Detecting Dataset Shift," dalam *Advances in Neural Information Processing Systems*, vol. 32, 2019. arXiv: 1810.11953.

[54] F. Abdi dan A. Ranaldo, "A Simple Estimation of Bid-Ask Spreads from Daily Close, High, and Low Prices," *The Review of Financial Studies*, vol. 30, no. 12, pp. 4437–4480, 2017. DOI: 10.1093/rfs/hhx084.

[55] S. A. Corwin dan P. Schultz, "A Simple Way to Estimate Bid-Ask Spreads from Daily High and Low Prices," *The Journal of Finance*, vol. 67, no. 2, pp. 719–760, 2012. DOI: 10.1111/j.1540-6261.2012.01729.x.

[56] M. Zhang, B. Zhu, Z. Li, S. Jin, dan Y. Xia, "Relationships among return and liquidity of cryptocurrencies," *Financial Innovation*, vol. 10, no. 1, p. 3, 2024. DOI: 10.1186/s40854-023-00532-z.

[57] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. DOI: 10.1023/A:1010933404324.

[58] D. A. Dickey dan W. A. Fuller, "Distribution of the Estimators for Autoregressive Time Series with a Unit Root," *Journal of the American Statistical Association*, vol. 74, no. 366a, pp. 427–431, 1979. DOI: 10.1080/01621459.1979.10482531.

[59] D. Kwiatkowski, P. C. Phillips, P. Schmidt, dan Y. Shin, "Testing the null hypothesis of stationarity against the alternative of a unit root," *Journal of Econometrics*, vol. 54, no. 1–3, pp. 159–178, 1992. DOI: 10.1016/0304-4076(92)90104-Y.

LAMPIRAN 1
CONTOH LAMPIRAN

Letakkan instrumen penelitian, data pendukung, atau rincian yang terlalu panjang untuk badan tulisan pada lampiran.